PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

SEQUENCE-LEVEL ROUTING FOR EFFICIENT QWEN3-0.6B INFERENCE IN INDONESIAN NEWS SUMMARIZATION



JOSEPH GREFFEN KOMALA
23/519909/PA/22318

PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN DEPARTEMEN ILMU KOMPUTER DAN ELEKTROTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

TAHUN

PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

SEQUENCE-LEVEL ROUTING FOR EFFICIENT QWEN3-0.6B INFERENCE IN INDONESIAN NEWS SUMMARIZATION

Usulan Penelitian



JOSEPH GREFFEN KOMALA
23/519909/PA/22318

PROGRAM STUDI ILMU KOMPUTER
DEPERTEMEN DEPARTEMEN ILMU KOMPUTER DAN ELEKTROTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

TAHUN

HALAMAN PENGESAHAN

PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

Telah dipersiapkan dan disusun oleh

JOSEPH GREFFEN KOMALA
23/519909/PA/22318

Telah dipertahankan di depan Tim Penguji
pada tanggal TANGGAL UJIAN BELUM DITETAPKAN

Susunan Tim Penguji

Dr. Nur Rokhman, S.Si., M.Kom. Pembimbing	NAMA DOSEN PENGUJI 1 Ketua Penguji
	NAMA DOSEN PENGUJI 2 Anggota Penguji

DAFTAR ISI

Halaman Judul **i**

Halaman Pengesahan **ii**

INTISARI **v**

ABSTRACT **vi**

I PENDAHULUAN **1**

1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Batasan Masalah 2
1.4 Tujuan Penelitian 4
1.5 Manfaat Penelitian 4

II PENELITIAN TERKAIT **5**

2.1 Efisiensi Inferensi dan Komputasi Adaptif 5
2.2 Pelompatan Lapisan Statis dan Routing Adaptif 6
2.3 Peringkasan Berita Bahasa Indonesia dan XL-Sum 7
2.4 Evaluasi Otomatis Peringkasan 7
2.5 Posisi Penelitian 8

III METODE DAN RANCANGAN PENELITIAN **9**

3.1 Deskripsi Umum Penelitian 9
3.2 Model dan Data Penelitian 9
3.2.1 Model 9
3.2.2 Dataset XL-Sum Bahasa Indonesia 10
3.3 Tahapan Penelitian 11
3.4 Perancangan Sistem 12
3.4.1 Arsitektur Sistem 12
3.4.2 Keputusan Routing dan Pelatihan Router 14
3.5 Rancangan Evaluasi 17
3.5.1 Metode Pembanding 17
3.5.2 Pemeriksaan Implementasi 18

3.5.3 Kualitas Ringkasan 18
3.5.4 Waktu Inferensi 19

IV JADWAL PENELITIAN **20**
4.1 Penyusunan Jadwal 20

INTISARI

Sequence-Level Routing untuk Efisiensi Inferensi Qwen3-0.6B pada Peringkasan Berita Bahasa Indonesia

Oleh

Joseph Greffen Komala
23/519909/PA/22318

Penelitian ini akan mengukur hubungan antara kualitas ringkasan dan efisiensi inferensi Qwen3-0.6B pada tugas peringkasan berita bahasa Indonesia menggunakan XL-Sum subset Indonesia. Mekanisme yang dikaji adalah pemilihan jalur eksekusi satu kali untuk setiap urutan masukan dan keluaran (*sequence-level routing*). Dari 28 lapisan model, lima kelompok tengah dapat dijalankan atau dilewati, sedangkan kelompok pertama dan terakhir selalu dijalankan. Router menentukan keputusan untuk kelompok tengah berdasarkan rata-rata representasi internal token artikel setelah kelompok pertama. Keputusan tersebut dipertahankan selama sisa pemrosesan prompt dan seluruh pembentukan token keluaran. Pelatihan dilakukan dalam dua tahap. Pada tahap pertama, parameter Qwen dibekukan dan router dilatih menggunakan target yang dibentuk melalui pencarian bertahap berdasarkan kerugian prediksi token dan proporsi kelompok aktif. Pada tahap kedua, router dibekukan dan adapter *Low-Rank Adaptation* (LoRA) dilatih untuk mengompensasi dampak pelompatan lapisan. Evaluasi mencakup tiga pendekatan utama—model penuh, pelompatan statis, dan routing adaptif—dengan LoRA pada masing-masing pendekatan. Routing adaptif tanpa LoRA juga diuji sebagai kontrol. Kualitas dinilai secara otomatis menggunakan F1 ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. F1 dihitung per artikel dan dirata-ratakan secara terpisah untuk setiap metrik; keempat metrik dilaporkan tanpa digabung menjadi satu skor. Efisiensi dinilai berdasarkan waktu total per artikel, termasuk biaya router, pemrosesan prompt, pembentukan keluaran, serta jumlah token keluaran sebagai informasi tambahan. Penelitian ini tidak mengasumsikan bahwa routing akan unggul. Jumlah data akan ditetapkan setelah kebutuhan waktu dan memori dipertimbangkan. Jadwal penelitian masih berupa rancangan dan akan disesuaikan dengan periode pelaksanaan yang ditetapkan.

ABSTRACT

Sequence-Level Routing for Efficient Qwen3-0.6B Inference in Indonesian News Summarization

By

Joseph Greffen Komala
23/519909/PA/22318

This study will measure the relationship between summary quality and inference efficiency for Qwen3-0.6B on Indonesian news summarization using the Indonesian subset of XL-Sum. It will examine sequence-level routing, which selects an execution path once for each input-and-output sequence. The model's 28 layers will be divided into seven consecutive groups of four. The first and last groups will always run, while a router will decide whether to run or skip each of the five middle groups. The router will use the mean internal representation of article tokens after the first group, and its decisions will remain fixed for the rest of prompt processing and all output-token generation. Training will use two stages. First, the router will be trained while Qwen remains frozen, using targets produced by a stepwise search based on teacher-forced token prediction loss and the proportion of active middle groups. Then, the router will be frozen and Low-Rank Adaptation (LoRA) adapters will be trained to compensate for layer skipping. Evaluation will compare three main approaches—full-model inference, static skipping, and adaptive routing—with LoRA trained for each approach. Adaptive routing without LoRA will also be evaluated as a control. Quality will be assessed automatically using ROUGE-1, ROUGE-2, ROUGE-L, and BERTScore F1, calculated per article and averaged separately for each metric. Efficiency will be measured by total inference time per article, including router overhead, prompt processing, and output generation; output length will be reported as supplementary information. The study will not assume that routing will outperform the alternatives. The data scale will be determined after considering time and memory requirements. The schedule remains provisional and will be aligned with the approved research period.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Peringkasan berita bahasa Indonesia merupakan tugas menyusun teks yang lebih ringkas dengan mempertahankan informasi utama artikel. Dalam peringkasan abstraktif, informasi tersebut dapat disampaikan kembali menggunakan susunan kalimat baru. Salah satu dataset untuk tugas ini adalah XL-Sum, yang menyediakan pasangan artikel berita dan ringkasan acuan dalam berbagai bahasa, termasuk bahasa Indonesia [Hasan et al., 2021]. Tugas peringkasan dapat dilakukan menggunakan model bahasa kausal, yaitu model yang menghasilkan teks dengan memprediksi token berikutnya berdasarkan teks sebelumnya. Token merupakan satuan potongan teks yang diproses oleh model.

Model bahasa kausal membentuk ringkasan secara autoregresif, yakni menghasilkan satu token setelah token sebelumnya. Pada setiap langkah pembentukan keluaran, model menjalankan komputasi melalui lapisan-lapisan Transformer, yaitu komponen berurutan dalam jaringan saraf yang mengolah representasi teks. Komputasi lapisan tersebut berulang selama ringkasan dibentuk. Oleh karena itu, pengurangan komputasi pada proses inferensi, yaitu penggunaan model untuk menghasilkan keluaran, menjadi salah satu fokus kajian efisiensi model bahasa [Jain et al., 2025].

Salah satu pendekatan yang relevan adalah pelompatan lapisan (*layer skipping*), yaitu melewati sebagian lapisan ketika model memproses masukan dan menghasilkan teks. Pelompatan dapat dilakukan secara statis dengan pola lapisan yang sama untuk semua masukan, atau secara adaptif dengan menyesuaikan jalur eksekusi berdasarkan masukan. Pada pendekatan adaptif, pemilihan jalur dilakukan oleh router, yaitu komponen yang menentukan lapisan atau kelompok lapisan yang akan dijalankan. Dengan pendekatan tersebut, pola eksekusi model dapat disesuaikan dengan artikel yang diproses [Jain et al., 2025, Wee et al., 2025].

Penelitian ini akan memusatkan kajian pada pemilihan jalur satu kali per artikel (*sequence-level routing*). Router akan menggunakan representasi artikel untuk menentukan kelompok lapisan yang dijalankan atau dilewati. Keputusan tersebut akan dipertahankan selama sisa pemrosesan masukan dan seluruh pembentukan

ringkasan. Dengan demikian, satu artikel akan menggunakan satu jalur eksekusi yang konsisten selama generasi.

Landasan pendekatan ini adalah FiRST dan PuDDing. FiRST mengkaji pemilihan lapisan berdasarkan masukan dengan router yang membuat keputusan pada tahap pemrosesan masukan [Jain et al., 2025]. PuDDing menggunakan router berbasis masukan untuk memilih himpunan lapisan yang dilewati [Wee et al., 2025]. Kedua penelitian tersebut menjadi dasar untuk mengkaji pemilihan jalur komputasi berdasarkan artikel pada tugas peringkasan berita bahasa Indonesia.

Kajian ini akan menggunakan Qwen3-0.6B, model bahasa kausal berukuran nominal 0,6 miliar parameter dengan 28 lapisan Transformer [Qwen Team, 2025], serta subset bahasa Indonesia dari XL-Sum. Pemilihan model dan dataset tersebut membatasi penelitian pada satu model dan satu konteks tugas yang jelas. Dalam konteks ini, penelitian akan mengkaji penerapan *sequence-level routing* untuk memahami pengaruh pemilihan jalur lapisan terhadap proses peringkasan berita bahasa Indonesia. Fokus tersebut menjadi dasar penyusunan rumusan masalah penelitian.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah penelitian ini adalah sebagai berikut.

1. Bagaimana pengaruh *sequence-level routing* terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B pada XL-Sum bahasa Indonesia?

2. Apakah routing adaptif dengan *Low-Rank Adaptation* (LoRA) memberikan keseimbangan kualitas dan efisiensi (*trade-off*) yang lebih baik daripada pelompatan lapisan statis dan model penuh dengan LoRA, serta bagaimana hasil routing adaptif berubah ketika LoRA tidak digunakan?

1.3 Batasan Masalah

Penelitian ini dibatasi pada ruang lingkup berikut.

1. Model yang digunakan adalah Qwen3-0.6B. Tugas penelitian adalah peringkasan berita bahasa Indonesia menggunakan pasangan artikel dan ringkasan acuan dari subset bahasa Indonesia XL-Sum. Data mengikuti pembagian

resmi pelatihan, validasi, dan pengujian. Data uji akan digunakan hanya untuk evaluasi akhir.

2. Mekanisme routing bekerja pada kelompok lapisan. Sebanyak 28 lapisan dibagi menjadi tujuh kelompok berurutan, masing-masing berisi empat lapisan. Kelompok pertama dan terakhir selalu dijalankan, sedangkan router menentukan apakah masing-masing dari lima kelompok tengah dijalankan atau dilewati. Keputusan dibuat satu kali per artikel setelah kelompok pertama dan dipertahankan selama sisa pemrosesan masukan serta seluruh pembentukan ringkasan.

3. Perbandingan mencakup model penuh dengan LoRA, pelompatan lapisan statis dengan LoRA, routing adaptif dengan LoRA, dan routing adaptif tanpa LoRA. LoRA merupakan metode penyesuaian model melalui pelatihan sejumlah parameter tambahan. Pada tiga pendekatan utama, adapter LoRA akan dilatih secara terpisah. Routing adaptif tanpa LoRA digunakan sebagai kontrol untuk mengukur perubahan yang berkaitan dengan penggunaan LoRA. Pola pelompatan statis dan konfigurasi eksperimen akan dipilih menggunakan data validasi.

4. Kualitas ringkasan akan dinilai menggunakan F1 ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. Skor dihitung per artikel, kemudian dirata-ratakan dan dilaporkan terpisah untuk setiap metrik. Efisiensi utama akan dinilai berdasarkan waktu inferensi total per artikel, termasuk pembentukan representasi artikel dan komputasi router. Waktu pemrosesan masukan (*prefill*) dan pembentukan token keluaran (*decoding*) akan dicatat secara terpisah. Semua metode akan menggunakan data uji, prompt, pengaturan generasi, perangkat, dan presisi numerik yang sama.

5. Evaluasi kualitas dibatasi pada metrik otomatis; penilaian manusia dan pemeriksaan faktualitas secara manual tidak dilakukan. Penelitian tidak menetapkan hipotesis berarah bahwa routing adaptif atau LoRA akan lebih unggul. Kesimpulan akan dibatasi pada model, tugas, data, dan kondisi eksperimen yang digunakan.

1.4 Tujuan Penelitian

Sesuai dengan rumusan masalah, penelitian ini bertujuan untuk:

1. menganalisis pengaruh *sequence-level routing* terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B pada XL-Sum bahasa Indonesia; dan
2. membandingkan keseimbangan kualitas dan efisiensi routing adaptif dengan LoRA terhadap pelompatan lapisan statis dan model penuh dengan LoRA, serta mengukur perubahan hasil routing adaptif melalui kontrol tanpa LoRA.

1.5 Manfaat Penelitian

Secara akademis, penelitian ini diharapkan menyediakan bukti empiris mengenai hubungan strategi pelompatan lapisan, kualitas ringkasan, dan waktu inferensi Qwen3-0.6B pada peringkasan berita bahasa Indonesia. Bukti tersebut diharapkan dapat menjadi bahan kajian untuk penelitian lanjutan mengenai pemilihan jalur komputasi berdasarkan masukan.

Secara metodologis, penelitian ini diharapkan menyediakan dokumentasi rancangan perbandingan antara model penuh, pelompatan lapisan statis, dan routing adaptif dengan LoRA, beserta kontrol routing adaptif tanpa LoRA. Protokol evaluasi yang memperhitungkan biaya router dalam waktu inferensi diharapkan dapat menjadi acuan untuk melakukan pengukuran pada rancangan serupa.

Secara praktis, penelitian ini diharapkan menjadi bahan pertimbangan bagi peneliti atau pengembang dalam menilai kelayakan penerapan *sequence-level routing* pada Qwen3-0.6B untuk peringkasan berita bahasa Indonesia. Pertimbangan tersebut akan didasarkan pada hubungan kualitas ringkasan dan waktu inferensi dalam kondisi eksperimen yang digunakan.

BAB II

PENELITIAN TERKAIT

2.1 Efisiensi Inferensi dan Komputasi Adaptif

Model Transformer memproses masukan melalui sejumlah lapisan, dan pada model decoder-only proses tersebut diulang untuk setiap token keluaran. Akibatnya, inferensi dapat menjadi mahal, terutama pada perangkat dengan sumber daya terbatas. Berbagai penelitian efisiensi inferensi berupaya mengurangi komputasi ini sambil mempertahankan kemampuan model menyelesaikan tugasnya.

Salah satu cara mengurangi komputasi adalah menjalankan jaringan dengan kedalaman yang lebih pendek. LayerDrop menggunakan *structured dropout* selama pelatihan agar subjaringan dengan kedalaman berbeda dapat digunakan saat inferensi dengan penurunan kinerja yang terbatas [Fan et al., 2020]. Pendekatan lain, yaitu *early exit*, menghentikan pemrosesan pada lapisan antara ketika keluaran dinilai telah cukup baik. Sebagai contoh, DeeBERT menambahkan titik keluar pada beberapa lapisan BERT sehingga sebagian masukan tidak perlu melewati seluruh jaringan [Xin et al., 2020].

Pada pembangkitan autoregresif, keputusan komputasi dapat dibuat pada tingkat urutan, token, atau lapisan. Confident Adaptive Language Modeling (CALM) mengalokasikan komputasi secara adaptif untuk setiap masukan dan langkah pembangkitan token. Pendekatan tersebut menunjukkan bahwa keputusan pada tingkat token memerlukan penanganan khusus terhadap dependensi antartoken dan representasi yang tidak dihitung pada langkah sebelumnya [Schuster et al., 2022]. LayerSkip juga mengkaji efisiensi model bahasa autoregresif melalui pelatihan dengan *layer dropout* dan *early-exit loss*, kemudian menggunakan keluaran lapisan awal untuk *self-speculative decoding* [Elhoushi et al., 2024].

Secara keseluruhan, pendekatan-pendekatan tersebut mengurangi komputasi dengan cara dan pada tahap yang berbeda; sebagian juga memerlukan pelatihan khusus pada model utama. Penelitian ini mengambil arah yang lebih terfokus: bobot dasar Qwen3-0.6B dibekukan ketika router dilatih, lalu adapter LoRA dilatih secara terpisah untuk mengompensasi dampak pelompatan lapisan. Perbedaan cara menentukan lapisan yang dilewati menjadi dasar pembahasan berikutnya mengenai strategi statis dan routing adaptif.

2.2 Pelompatan Lapisan Statis dan Routing Adaptif

Pelompatan lapisan dapat diterapkan dengan pola tetap atau dengan keputusan yang menyesuaikan masukan. Strategi statis menjalankan pola lapisan yang sama untuk semua artikel sehingga sederhana dan mudah direproduksi, tetapi tidak menyesuaikan komputasi dengan isi artikel. Sebaliknya, routing adaptif memilih jalur eksekusi berdasarkan karakteristik setiap masukan. Perbedaan ini relevan karena artikel dengan tingkat kesulitan dan struktur informasi yang berbeda mungkin memerlukan jumlah komputasi yang berbeda pula.

PuDDing menggunakan prompt untuk memilih pola kedalaman dari beberapa pola lapisan yang telah disiapkan. Hasilnya menunjukkan potensi routing berbasis prompt untuk mengurangi komputasi, tetapi pendekatan tersebut memilih di antara pola yang telah ditentukan dan dievaluasi pada tugas penalaran akal sehat [Wee et al., 2025]. Penelitian ini menggunakan keluaran biner terpisah untuk setiap kelompok lapisan tengah. Dengan demikian, pola route tidak diperlakukan sebagai kelas dengan identitas tertentu dan jumlah lapisan aktif dapat berbeda antarartikel.

FiRST memperluas gagasan routing berbasis prompt dengan router khusus pada lapisan dan keputusan yang dibuat pada tahap *prefill*, kemudian dipakai selama proses pembentukan token keluaran. FiRST melatih router lebih dahulu dengan backbone beku, lalu membekukan router dan melatih adapter LoRA pada modul attention dan FFN untuk memulihkan kualitas setelah pelompatan lapisan [Jain et al., 2025]. Penelitian ini mengadopsi pola pelatihan dua tahap tersebut, tetapi tetap menggunakan satu router pada tingkat kelompok lapisan, bukan router terpisah untuk setiap lapisan. Target router penelitian ini dibentuk melalui pencarian bertahap berdasarkan kerugian prediksi token dan proporsi kelompok aktif.

Beberapa penelitian juga menunjukkan bahwa pengurangan komputasi pada model autoregresif harus memperhatikan cara representasi dan *key-value cache* dikelola. FFN-SkipLLM melaporkan bahwa strategi *early exit* yang tidak tepat dapat berkaitan dengan keruntuhan generasi, halusinasi, dan penurunan kualitas, lalu mengusulkan pelompatan blok feed-forward yang tidak memerlukan penanganan KV cache dengan cara yang sama [Jaiswal et al., 2024]. Oleh karena itu, penelitian ini memasukkan pemeriksaan bahwa lapisan yang dilewati benar-benar tidak dieksekusi, route tidak berubah selama decoding, dan KV cache konsisten. Efisiensi utama juga diukur menggunakan waktu inferensi aktual, bukan hanya jumlah lapisan yang dilewati.

2.3 Peringkasan Berita Bahasa Indonesia dan XL-Sum

Untuk menguji perbedaan strategi tersebut pada tugas yang terukur, penelitian ini menggunakan XL-Sum, dataset peringkasan abstraktif multibahasa yang menyediakan pasangan artikel berita dan ringkasan acuan dalam 44 bahasa, termasuk bahasa Indonesia [Hasan et al., 2021]. Pasangan ini dapat digunakan baik untuk membentuk target pelatihan router maupun untuk menilai ringkasan hasil generasi. Penelitian dibatasi pada subset bahasa Indonesia, dengan prosedur pemrosesan data yang sama bagi seluruh metode pembanding.

Pada dataset tersebut, penelitian menggunakan Qwen3-0.6B, model bahasa kausal dengan 28 lapisan [Qwen Team, 2025]. Bobot dasarnya dibekukan selama pelatihan router, kemudian adapter LoRA dilatih pada tahap berikutnya. Rancangan evaluasi membandingkan model penuh, pola statis, dan routing adaptif dengan LoRA, serta menyertakan routing adaptif tanpa LoRA sebagai kontrol. Dengan demikian, perbandingan tidak hanya menguji strategi routing, tetapi juga memungkinkan pengamatan atas kontribusi LoRA.

2.4 Evaluasi Otomatis Peringkasan

ROUGE merupakan keluarga metrik yang membandingkan tumpang tindih unit teks antara ringkasan keluaran dan ringkasan acuan. ROUGE-N mengukur kecocokan n-gram, sedangkan ROUGE-L menggunakan subsekuens umum terpanjang [Lin, 2004]. Penelitian ini menggunakan ROUGE-1, ROUGE-2, dan ROUGE-L untuk menangkap kecocokan kata, pasangan kata berurutan, dan struktur urutan teks.

BERTScore melengkapi ROUGE dengan membandingkan representasi kontekstual token menggunakan kemiripan kosinus [Zhang et al., 2020]. Metrik ini dapat menangkap kemiripan makna yang tidak selalu menghasilkan tumpang tindih kata secara langsung. Namun, kedua kelompok metrik tersebut tetap merupakan ukuran kecocokan terhadap acuan. Forde et al. menunjukkan bahwa metrik otomatis dapat kurang andal untuk menilai kualitas peringkasan multibahasa, dengan masalah yang lebih besar pada bahasa Indonesia [Forde et al., 2024]. Karena itu, penelitian ini menggunakan beberapa metrik secara terpisah dan tidak menyimpulkan bahwa skor tersebut menjamin faktualitas atau kualitas ringkasan secara menyeluruh.

2.5 Posisi Penelitian

Uraian penelitian terdahulu memperlihatkan beragam cara mengurangi komputasi Transformer, mulai dari pelatihan agar model mampu menggunakan kedalaman lebih pendek, *early exit*, hingga routing berbasis prompt. Meski memiliki tujuan serupa, pendekatan tersebut berbeda dalam tingkat pengambilan keputusan, kebutuhan perubahan pada model utama, tugas evaluasi, dan cara mengukur efisiensi. Perbedaan ini menunjukkan perlunya pengujian dalam konteks tugas dan rancangan yang spesifik.

Penelitian ini menguji *sequence-level routing* pada Qwen3-0.6B untuk peringkasan berita bahasa Indonesia menggunakan XL-Sum. Router membaca representasi token artikel setelah kelompok pertama dan memilih secara biner apakah setiap kelompok dari lima kelompok lapisan tengah dijalankan atau dilewati. Keputusan yang sama dipertahankan selama sisa pemrosesan prompt dan seluruh proses pembentukan token keluaran. Router dilatih saat parameter Qwen dibekukan; setelah itu, router dibekukan dan LoRA dilatih sebagai tahap kompensasi. Routing adaptif tanpa LoRA menjadi kontrol untuk membandingkan hasil dengan konfigurasi yang menggunakan LoRA.

Evaluasi membandingkan routing adaptif dengan model penuh dan satu pola pelompatan statis yang dipilih menggunakan data validasi. LoRA dilatih pada masing-masing pendekatan utama, sedangkan routing adaptif tanpa LoRA menjadi kontrol. Perbandingan mencakup kualitas keluaran dan waktu inferensi aktual pada perangkat serta pengaturan yang sama, termasuk biaya router, *prefill*, dan *decoding*. Dengan demikian, penelitian menguji trade-off kualitas–efisiensi routing adaptif serta perubahan hasil ketika LoRA digunakan. Penelitian ini tidak mengklaim bahwa penggunaan router, pembagian kelompok lapisan, atau model Qwen3-0.6B tersebut merupakan penerapan pertama.

BAB III

METODE DAN RANCANGAN PENELITIAN

3.1 Deskripsi Umum Penelitian

Penelitian ini dirancang sebagai eksperimen yang mengukur pengaruh pelompatan kelompok lapisan terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B. Untuk setiap artikel berita berbahasa Indonesia, model akan menghasilkan ringkasan, sementara router ringan menentukan kelompok lapisan yang perlu dijalankan berdasarkan representasi artikel dalam prompt. Keputusan routing dibuat satu kali per artikel dan dipertahankan selama pemrosesan prompt serta pembentukan seluruh token ringkasan.

Untuk menilai kinerja routing, hasilnya akan dibandingkan dengan dua acuan: Qwen3-0.6B yang menjalankan seluruh lapisan dan metode pelompatan statis yang menggunakan pola kelompok lapisan tetap untuk semua artikel. Kualitas ringkasan akan dinilai menggunakan ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. Efisiensi utama diukur berdasarkan waktu inferensi pada perangkat dan pengaturan yang sama, sedangkan jumlah lapisan aktif dicatat sebagai informasi pendukung.

3.2 Model dan Data Penelitian

3.2.1 Model

Model yang digunakan adalah Qwen3-0.6B dengan identitas `Qwen/Qwen3-0.6B`. Model ini memiliki 28 lapisan transformer [Qwen Team, 2025]. Untuk keperluan routing, lapisan dibagi menjadi tujuh kelompok berurutan yang masing-masing berisi empat lapisan. Jika lapisan diberi nomor dari satu, kelompok G_i mencakup lapisan $4i - 3$ sampai dengan $4i$, untuk $i = 1, \ldots, 7$.

Kelompok pertama (G_1) dan kelompok terakhir (G_7) selalu dijalankan. Router menentukan apakah masing-masing dari lima kelompok di antaranya (G_2 sampai G_6) dijalankan atau dilewati. Ketentuan untuk G_1 dan G_7 merupakan bagian dari rancangan eksperimen; penelitian ini tidak menganggap kedua kelompok tersebut telah terbukti lebih penting daripada kelompok lainnya.

Model dijalankan dalam mode non-thinking. Pengujian menggunakan pemilihan token dengan skor tertinggi pada setiap langkah, tanpa pengambilan sampel acak,

dengan pengaturan `do_sample=False` dan `num_beams=1`. Panjang seluruh urutan dibatasi hingga 4.096 token. Prompt, termasuk instruksi dan format chat, paling panjang 3.840 token, sedangkan ringkasan keluaran dibatasi hingga 256 token. Pembentukan ringkasan berhenti ketika model menghasilkan token akhir respons atau ketika batas keluaran tercapai. Batas dan aturan ini digunakan sama untuk seluruh metode.

Versi bobot model, tokenizer, dan perangkat lunak yang digunakan akan dicatat sebelum evaluasi agar konfigurasi penelitian dapat dilaporkan dengan jelas.

3.2.2 Dataset XL-Sum Bahasa Indonesia

Data penelitian berasal dari konfigurasi bahasa Indonesia pada XL-Sum [CSE BUET NLP Group, t.t.a], yang menyediakan pasangan artikel berita dan ringkasan acuan. Artikel menjadi masukan model; ringkasan acuan digunakan untuk menyiapkan target pelatihan router dan menilai hasil generasi. Data mengikuti pembagian pelatihan, validasi, dan pengujian yang tersedia pada dataset [CSE BUET NLP Group, t.t.b]. Untuk mencegah kebocoran informasi, data uji hanya digunakan pada evaluasi akhir, bukan untuk melatih router atau memilih konfigurasi.

Jumlah artikel yang digunakan pada setiap bagian belum ditetapkan. Jumlah tersebut akan dipilih setelah waktu pemrosesan dan kebutuhan memori diukur. Jika hanya sebagian data digunakan, artikel dipilih secara acak tanpa pengembalian pada setiap bagian dengan seed 42. Identitas artikel yang terpilih akan disimpan, dan himpunan data uji yang sama akan digunakan untuk semua metode.

Pembersihan teks dan penghapusan duplikasi

Pembersihan hanya menghapus spasi dan baris kosong di awal serta akhir artikel dan ringkasan acuan. Huruf besar, tanda baca, spasi di antara kata, dan isi lainnya dipertahankan. Pasangan artikel dan ringkasan dikeluarkan apabila salah satunya kosong setelah pembersihan. Jumlah pasangan yang dikeluarkan dicatat.

Dua artikel dinyatakan duplikat apabila teksnya sama persis setelah pembersihan. Jika duplikasi terjadi pada bagian data yang sama, kemunculan pertama menurut urutan dataset dipertahankan beserta ringkasan acuannya. Jika artikel yang sama ditemukan pada lebih dari satu bagian data, pasangan pada data uji dipertahankan jika tersedia; jika tidak, pasangan pada data validasi dipertahankan daripada pasangan pada data latih. Salinan pada bagian lain dihapus dan tidak dipindahkan. Pemeriksaan duplikasi dilakukan sebelum pemilihan sebagian data, dan jumlah serta identitas

pasangan yang dihapus dicatat.

Pemeriksaan batas panjang

Prompt lengkap disusun dengan format yang dijelaskan pada bagian berikut, kemudian jumlah potongan teks (token) di dalamnya dihitung menggunakan tokenizer Qwen3-0.6B. Artikel dikeluarkan jika prompt lengkap melebihi 3.840 token. Artikel tidak dipotong. Ringkasan acuan juga dikeluarkan jika panjangnya melebihi 256 token, termasuk token akhir respons; ringkasan tidak dipotong. Aturan ini diterapkan pada data latih, validasi, dan uji. Pasangan prompt dan ringkasan acuan yang digunakan dalam pelatihan diperiksa agar jumlah token gabungannya tidak melebihi 4.096. Jumlah pasangan yang dikeluarkan karena batas panjang dan jumlah akhir pada setiap bagian data akan dicatat.

Format prompt

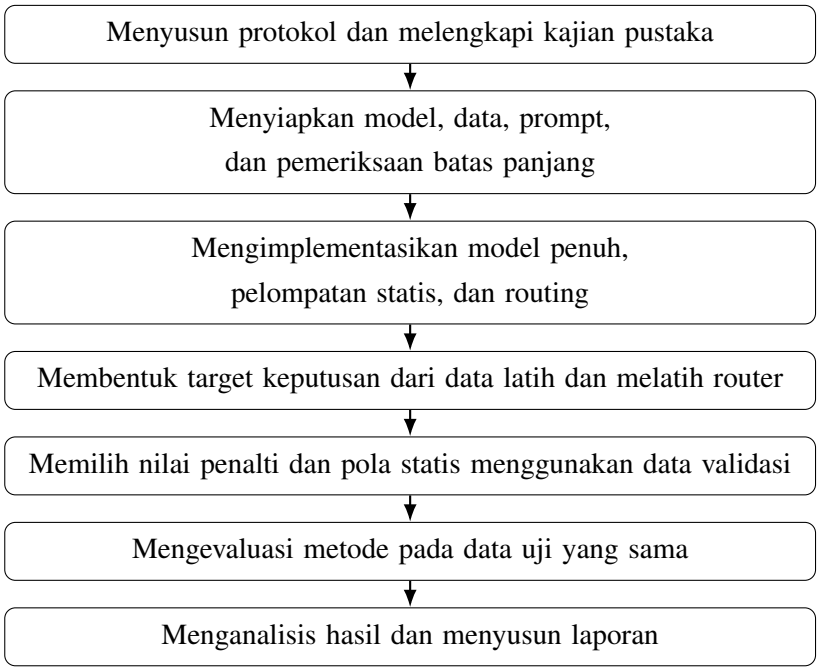
Instruksi dan artikel disampaikan sebagai pesan pengguna dalam format chat Qwen dengan mode non-thinking. Teks prompt yang digunakan adalah sebagai berikut. Penanda `{artikel}` diganti dengan teks artikel secara utuh.

> Ringkas artikel berita berikut dalam bahasa Indonesia. Pertahankan informasi utama dan jangan menambahkan informasi yang tidak terdapat dalam artikel.
>
> Artikel:
> `{artikel}`

Format tersebut digunakan untuk menyiapkan masukan pelatihan dan menghasilkan ringkasan dengan seluruh metode. Penghitungan batas masukan dilakukan setelah prompt disusun dalam format chat, termasuk penanda awal respons asisten.

3.3 Tahapan Penelitian

Pelaksanaan penelitian disusun berurutan agar data uji tetap terpisah dari proses pengembangan dan pemilihan metode. Tahapannya meliputi penyusunan protokol, persiapan data dan model, implementasi serta pemeriksaan metode, pelatihan router, pemilihan konfigurasi menggunakan data validasi, dan evaluasi akhir. Setelah itu, hasil dianalisis dan dilaporkan.



Gambar 3.1: Bagan alir penelitian.

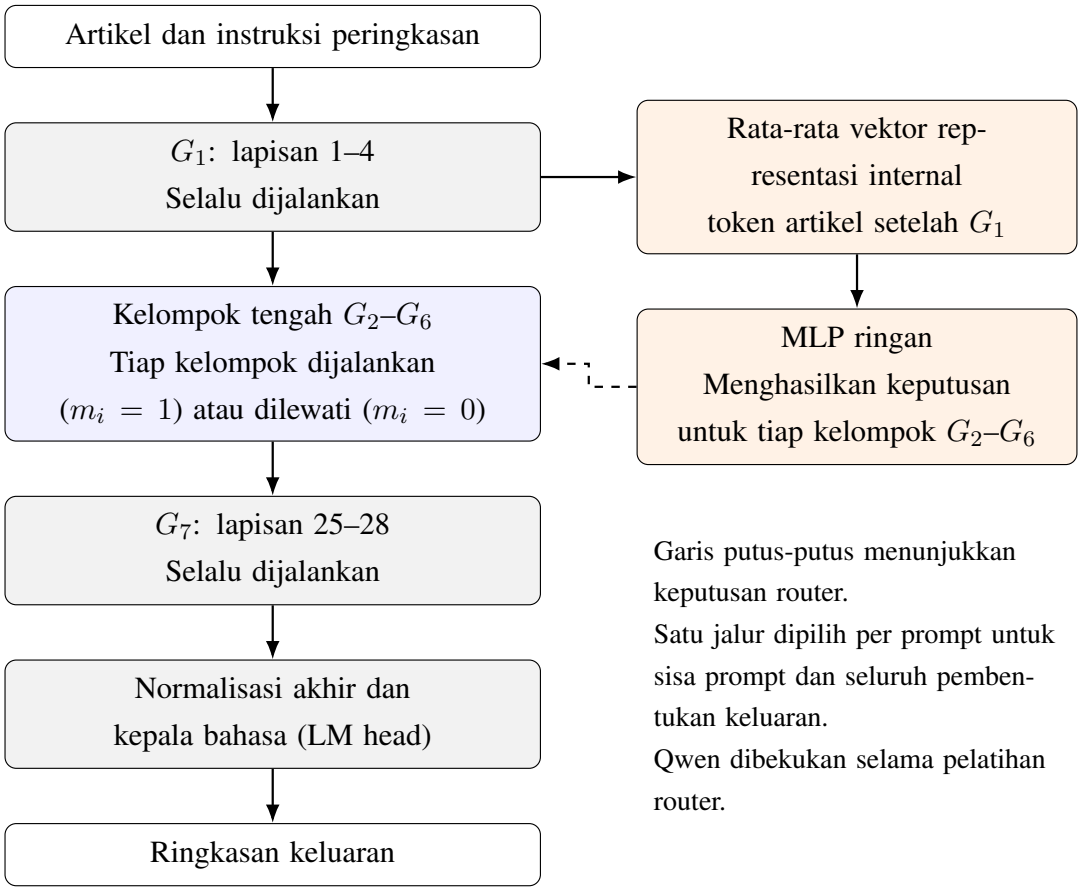
Gambar 3.1 merangkum tahapan tersebut, dari persiapan penelitian hingga evaluasi pada data uji yang hanya dilakukan setelah konfigurasi ditetapkan.

Pemeriksaan kebenaran implementasi dilakukan sebagai bagian dari eksperimen utama untuk memastikan setiap metode berjalan sesuai rancangan. Dengan demikian, pemeriksaan ini bukan evaluasi awal yang menggantikan pengujian utama; implementasi routing dan pengukurannya sendiri merupakan pekerjaan yang direncanakan dalam penelitian ini.

3.4 Perancangan Sistem

3.4.1 Arsitektur Sistem

Untuk setiap artikel, pemrosesan dimulai dengan menjalankan kelompok lapisan pertama. Representasi artikel yang dihasilkan pada tahap ini menjadi masukan router, yang kemudian menentukan kelompok tengah mana yang akan dijalankan. Setelah keputusan dibuat, model meneruskan pemrosesan melalui kelompok terpilih dan kelompok terakhir sebelum kepala bahasa menghasilkan ringkasan.



Gambar 3.2: Arsitektur sequence-level routing pada Qwen3-0.6B.

Sebagaimana ditunjukkan pada Gambar 3.2, keluaran kelompok pertama memiliki dua fungsi: membentuk representasi artikel untuk router dan meneruskan pemrosesan prompt. Berdasarkan representasi tersebut, router menghasilkan lima keputusan, masing-masing untuk kelompok G_2 hingga G_6, yang menentukan jalur eksekusi selanjutnya.

Representasi artikel dihitung sebagai rata-rata representasi internal token artikel setelah kelompok pertama. Token instruksi, token khusus, dan padding tidak disertakan dalam perhitungan. Keluaran kelompok pertama yang telah dihitung untuk router digunakan kembali untuk melanjutkan pemrosesan prompt, sehingga kelompok tersebut tidak perlu dijalankan ulang. Setelah keputusan dibuat, pola kelompok yang dijalankan tetap sama selama sisa pemrosesan prompt dan seluruh pembentukan ringkasan. Penyimpanan nilai key dan value (KV cache), yang digunakan kembali saat model membentuk token berikutnya, disiapkan untuk lapisan yang dijalankan. Waktu untuk menghitung representasi dan menjalankan router termasuk dalam pen-

gukuran waktu inferensi.

3.4.2 Keputusan Routing dan Pelatihan Router

Keputusan untuk setiap kelompok

Untuk setiap kelompok tengah G_i, dengan $i = 2, \ldots, 6$, router menghasilkan keputusan $m_i \in \{0, 1\}$. Nilai $m_i = 1$ berarti kelompok dijalankan, sedangkan $m_i = 0$ berarti kelompok dilewati. Dengan demikian, pola keputusan lengkap ditulis sebagai $(1, m_2, m_3, m_4, m_5, m_6, 1)$. Jumlah lapisan yang dijalankan dapat berbeda untuk setiap artikel, dengan perubahan sebanyak empat lapisan. Router membuat keputusan satu kali berdasarkan prompt dan tidak memilih ulang kelompok untuk setiap token ringkasan.

Bentuk dan masukan router

Router menggunakan MLP ringan dengan masukan berupa representasi artikel setelah kelompok pertama dan menghasilkan keputusan biner untuk masing-masing kelompok tengah. Rincian arsitektur internal dan konfigurasi router, termasuk bentuk lapisan dan aturan operasional untuk menghasilkan keputusan, akan ditetapkan pada tahap implementasi dan pemilihan konfigurasi menggunakan data validasi. Pada saat digunakan untuk membuat ringkasan, router hanya menerima representasi artikel dari prompt dan tidak menggunakan ringkasan acuan.

Pembentukan target pelatihan

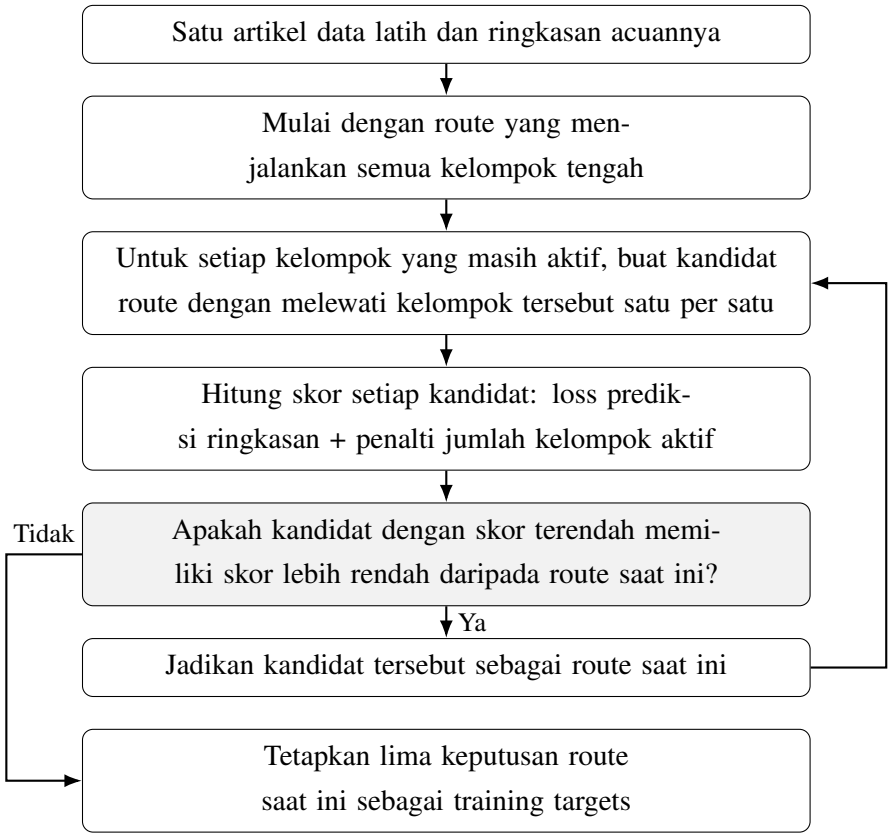
Sebelum router dilatih, perlu disiapkan contoh keputusan yang akan dipelajarinya. Contoh ini disebut *training targets*. Target dibuat untuk setiap artikel pada data latih dengan menggunakan artikel dan ringkasan acuannya. Ringkasan acuan membantu menilai apakah suatu pola kelompok lapisan menghasilkan prediksi yang mendekati ringkasan tersebut. Untuk penilaian ini, model menerima token ringkasan acuan sebelumnya sebagai masukan saat memprediksi token berikutnya. Cara tersebut disebut *teacher forcing*.

Setiap pola kelompok lapisan disebut *route*. Untuk menilai route, dihitung *loss*, yaitu nilai yang menunjukkan kesalahan prediksi token. Nilai loss yang lebih rendah berarti prediksi model lebih sesuai dengan ringkasan acuan. Skor route juga memperhitungkan jumlah kelompok tengah yang dijalankan:

$$J(m) = \mathrm{NLL}(m) + \lambda C(m), \qquad C(m) = \frac{m_2 + m_3 + m_4 + m_5 + m_6}{5}, \qquad (3.1)$$

dengan m sebagai route yang sedang dinilai dan $J(m)$ sebagai skor total route tersebut. Nilai $\mathrm{NLL}(m)$ adalah rata-rata kerugian prediksi token atau *negative log-likelihood* (NLL); nilai yang lebih rendah menunjukkan bahwa prediksi model lebih sesuai dengan ringkasan acuan. Nilai $C(m)$ menunjukkan proporsi kelompok tengah yang dijalankan. Sebagai contoh, jika tiga dari lima kelompok tengah dijalankan, maka $C(m) = 3/5 = 0{,}6$. Nilai λ adalah bobot yang mengatur pengaruh jumlah kelompok aktif terhadap skor. Karena semua kelompok berisi empat lapisan, proporsi kelompok aktif juga menunjukkan proporsi lapisan tengah yang dijalankan. Dengan demikian, $J(m)$ menggabungkan kerugian prediksi ringkasan dan jumlah kelompok aktif; route dengan skor $J(m)$ lebih rendah lebih dipilih.

Pencarian target untuk setiap artikel dimulai dari route yang menjalankan semua kelompok tengah. Pada setiap putaran, dibuat beberapa kandidat dengan melewati satu kelompok aktif yang berbeda, lalu skor setiap kandidat dihitung. Kandidat dengan skor lebih rendah daripada route saat ini menjadi route baru dan pencarian dilanjutkan. Jika tidak ada kandidat yang menurunkan skor, pencarian berhenti dan route saat ini dipertahankan. Lima keputusan pada route akhir menjadi target pelatihan: nilai 1 berarti kelompok dijalankan, sedangkan nilai 0 berarti kelompok dilewati. Karena pencarian hanya bergerak dengan melewati kelompok aktif, metode ini tidak menjamin bahwa route yang ditemukan memiliki skor terendah di antara seluruh 32 kemungkinan.



Gambar 3.3: Pembentukan target keputusan router untuk satu artikel.

Gambar 3.3 merangkum pencarian bertahap tersebut. Pada setiap langkah, hanya penghapusan satu kelompok aktif yang dipertimbangkan; pencarian berhenti ketika tidak ada penghapusan tunggal yang menurunkan skor.

Setelah target untuk artikel data latih terbentuk, router dilatih untuk memprediksi lima keputusan tersebut berdasarkan representasi artikel. Dengan demikian, ringkasan acuan digunakan untuk menyiapkan target pelatihan, sedangkan router saat digunakan hanya menerima artikel pada prompt.

Pelatihan dan pemilihan nilai penalti

Router dilatih untuk memprediksi lima keputusan hasil pembentukan target. Pelatihan menggunakan fungsi kerugian untuk mengukur kesalahan prediksi biner sebelum keluaran router diubah menjadi keputusan aktif atau lewati (*binary cross-entropy with logits*). Bobot Qwen, termasuk bobot yang menghasilkan representasi artikel, dibekukan selama pelatihan router. Konfigurasi awal menggunakan metode pengoptimalan AdamW, laju pembelajaran 10^{-3}, peluruhan bobot 10^{-4}, paling

banyak 50 epoch (putaran pelatihan atas seluruh data latih), dan penghentian awal jika kinerja validasi tidak membaik selama lima epoch berturut-turut.

Setelah router dilatih, adapter LoRA dilatih pada modul attention dan FFN di seluruh lapisan Qwen. Karena kelompok pertama ikut diperbarui oleh LoRA dan keluarannya digunakan untuk membentuk masukan router, representasi yang diterima router dapat berubah setelah tahap ini. Prosedur untuk menjaga kesesuaian masukan router pada pelatihan dan inferensi akan ditetapkan serta diperiksa sebagai bagian implementasi eksperimen.

Pembentukan target bergantung pada nilai λ. Kandidat yang dibandingkan adalah $\{0,0{,}01, 0{,}05, 0{,}10, 0{,}20\}$. Satu nilai dipilih menggunakan data validasi dan digunakan dalam pembentukan target router serta pemilihan pola pelompatan statis. Kriteria operasional untuk memilih nilai tersebut akan ditetapkan sebelum evaluasi data uji. Seed pemilihan subset adalah 42, sedangkan seed utama pelatihan router adalah 43. Seed tambahan 44 dan 45 dapat digunakan untuk analisis ketahanan jika sumber daya mencukupi; hasilnya, apabila tersedia, dilaporkan terpisah dari hasil utama. Data uji tidak digunakan untuk membentuk target atau memilih konfigurasi.

3.5 Rancangan Evaluasi

3.5.1 Metode Pembanding

Evaluasi membandingkan tiga pendekatan utama: model penuh, pelompatan statis, dan routing adaptif. Pada model penuh, seluruh kelompok lapisan dijalankan; pada pelompatan statis, satu pola kelompok digunakan untuk semua artikel; sedangkan pada routing adaptif, router memilih pola berdasarkan setiap prompt. LoRA dilatih secara terpisah pada data latih untuk masing-masing pendekatan utama, dengan pemilihan konfigurasi menggunakan data validasi. Routing adaptif tanpa LoRA menjadi kontrol tambahan untuk membandingkan kualitas dan efisiensi dengan konfigurasi routing yang menggunakan LoRA.

Pola pelompatan statis dipilih menggunakan objective pada Persamaan 3.1, nilai λ terpilih, dan data validasi. Cara mengagregasikan skor antarartikel validasi untuk membandingkan pola akan ditetapkan sebelum evaluasi data uji. Jika beberapa pola memperoleh skor yang sama, dipilih pola dengan kelompok aktif lebih sedikit. Jika skor tetap sama, dipilih pola dengan urutan leksikografis terkecil, dengan nilai 0 didahulukan daripada 1. Pola terpilih kemudian digunakan untuk seluruh artikel dan proses pembentukan ringkasan. Data uji tidak digunakan dalam pemilihan.

3.5.2 Pemeriksaan Implementasi

Sebelum hasil dievaluasi, implementasi akan diperiksa untuk memastikan bahwa model menghasilkan perilaku yang sesuai dengan model penuh ketika semua lapisan dijalankan. Pemeriksaan juga memastikan bahwa kelompok yang dipilih untuk dilewati tidak dieksekusi, keputusan router tidak berubah selama pembentukan ringkasan, dan penyimpanan nilai key dan value digunakan secara konsisten. Pemeriksaan diperlukan agar perbandingan kualitas dan waktu mencerminkan metode yang dirancang.

3.5.3 Kualitas Ringkasan

Kualitas ringkasan keluaran dibandingkan dengan ringkasan acuan menggunakan ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. ROUGE-1 mengukur kesamaan kata tunggal, ROUGE-2 mengukur kesamaan pasangan kata berurutan, dan ROUGE-L mengukur kesamaan urutan kata terpanjang. BERTScore membandingkan kemiripan representasi kontekstual kata pada ringkasan keluaran dan ringkasan acuan [Zhang et al., 2020].

Untuk setiap metrik, nilai F1 akan dihitung untuk masing-masing artikel, lalu dirata-ratakan dengan bobot yang sama bagi setiap artikel. Keempat metrik dilaporkan secara terpisah. Hasil metrik kemiripan terhadap acuan tidak dengan sendirinya membuktikan bahwa semua informasi dalam ringkasan faktual atau bahwa ringkasan berkualitas dalam seluruh aspek. Pilihan implementasi ROUGE dan konfigurasi BERTScore masih akan ditetapkan sebelum evaluasi.

Perbedaan rata-rata F1 antara routing adaptif dan setiap metode pembanding akan dilengkapi interval kepercayaan dua sisi 95% menggunakan bootstrap berpasangan. Sebanyak 10.000 pengambilan ulang dilakukan dengan mengambil artikel uji secara acak dengan pengembalian. Indeks artikel yang sama digunakan untuk kedua metode pada setiap pengambilan ulang, lalu selisih rata-rata F1 dihitung. Batas interval menggunakan persentil 2,5% dan 97,5% dari selisih hasil pengambilan ulang. Seed bootstrap adalah 42 dan digunakan terpisah dari seed pemilihan data serta seed pelatihan router. Interval dihitung secara terpisah untuk setiap metrik dan setiap pasangan perbandingan. Interval ini menggambarkan variasi antarartikel, bukan variasi antarseed pelatihan.

3.5.4 Waktu Inferensi

Efisiensi utama dinilai menggunakan waktu inferensi aktual pada perangkat dan pengaturan yang sama. Waktu total per artikel mencakup waktu untuk menghitung representasi artikel dan menjalankan router, memproses sisa prompt, serta membentuk ringkasan. Waktu pemrosesan prompt (*prefill*) dan waktu pembentukan ringkasan (*decoding*) juga dicatat secara terpisah. Jumlah token keluaran dicatat agar perbedaan waktu dapat ditafsirkan bersama panjang ringkasan yang dihasilkan. Jumlah kelompok aktif dilaporkan sebagai informasi tambahan.

Seluruh metode menggunakan prompt, batas token, mode non-thinking, dan pengaturan pembentukan ringkasan yang sama. Pengukuran menggunakan ukuran batch satu serta mencakup pemanasan dan pengulangan. Jumlah pemanasan, jumlah pengulangan, dan statistik ringkasan waktu akan ditetapkan sebelum evaluasi. Perangkat, presisi, versi perangkat lunak, serta pengaturan lain yang memengaruhi waktu juga akan dicatat. Pola kelompok yang dipilih router akan dirangkum untuk melihat seberapa sering setiap pola digunakan.

BAB IV

JADWAL PENELITIAN

4.1 Penyusunan Jadwal

Tabel berikut menyajikan rancangan jadwal dalam empat tahap bulanan. Durasi dan periode pelaksanaan ini masih bersifat sementara dan akan disesuaikan dengan jadwal penelitian yang ditetapkan. Kegiatan mengikuti tahapan pada Bab III, mulai dari persiapan kajian dan data, implementasi eksekusi kondisional, pelatihan router dan LoRA, hingga evaluasi, analisis, dan penulisan laporan. Dokumentasi dilakukan seiring pekerjaan teknis.

Tabel 4.1: Jadwal Penelitian

Kegiatan	**Bulan 1**	**Bulan 2**	**Bulan 3**	**Bulan 4**
Kajian literatur, finalisasi rancangan, dan persiapan data	•			
Implementasi model penuh, static skipping, router, dan adapter LoRA		•		
Pelatihan router dan LoRA; evaluasi kualitas serta efisiensi			•	
Analisis hasil dan penulisan laporan			•	•
Revisi dan finalisasi laporan				•

Penulisan laporan dilakukan secara paralel selama penelitian, sedangkan pembagian bulan pada tabel menunjukkan fokus utama setiap tahap.

DAFTAR PUSTAKA

CSE BUET NLP Group. XL-Sum: Dataset card. https://huggingface.co/datasets/csebuetnlp/xlsum, t.t.a. Diakses pada 6 Oktober 2026.

CSE BUET NLP Group. XL-Sum: Repository readme. https://github.com/csebuetnlp/xl-sum/blob/master/README.md, t.t.b. Diakses pada 6 Oktober 2026.

Mostafa Elhoushi, Akshat Shrivastava, Diana Liskovich, Basil Hosmer, Bram Wasti, Liangzhen Lai, Anas Mahmoud, Bilge Acun, Saurabh Agarwal, Ahmed Roman, Ahmed Aly, Beidi Chen, and Carole-Jean Wu. Layerskip: Enabling early exit inference and self-speculative decoding. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 12622–12642. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.acl-long.681. URL https://aclanthology.org/2024.acl-long.681/.

Angela Fan, Edouard Grave, and Armand Joulin. Reducing transformer depth on demand with structured dropout. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=SylO2yStDr.

Jessica Zosa Forde, Ruochen Zhang, Lintang Sutawika, Alham Fikri Aji, Samuel Cahyawijaya, Genta Indra Winata, Minghao Wu, Carsten Eickhoff, Stella Biderman, and Ellie Pavlick. Re-evaluating evaluation for multilingual summarization. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 19476–19493. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.emnlp-main.1085. URL https://aclanthology.org/2024.emnlp-main.1085/.

Tahmid Hasan, Abhik Bhattacharjee, Md. Saiful Islam, Kazi Mubasshir, Yuan-Fang Li, Yong-Bin Kang, M. Sohel Rahman, and Rifat Shahriyar. XL-Sum: Large-scale multilingual abstractive summarization for 44 languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pages 4693–4703. Association for Computational Linguistics, 2021. doi: 10.18653/v1/2021.findings-acl.413. URL https://aclanthology.org/2021.findings-acl.413/.

Akriti Jain, Saransh Sharma, Koyel Mukherjee, and Soumyabrata Pal. FiRST: Finetuning router-selective transformers for input-adaptive latency reduction. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 21957–21975. Association for Computational Linguistics, 2025. doi: 10.18653/v1/2025.findings-emnlp.1197. URL https://aclanthology.org/2025.findings-emnlp.1197/.

Ajay Kumar Jaiswal, Bodun Hu, Lu Yin, Yeonju Ro, Tianlong Chen, Shiwei Liu, and Aditya Akella. FFN-SkipLLM: A hidden gem for autoregressive decoding with adaptive feed forward skipping. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 16943–16956. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.emnlp-main.941. URL https://aclanthology.org/2024.emnlp-main.941/.

Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81. Association for Computational Linguistics, 2004. URL https://aclanthology.org/W04-1013/.

Qwen Team. Qwen3-0.6B: Model card. https://huggingface.co/Qwen/Qwen3-0.6B, 2025. Diakses pada 6 Oktober 2026.

Tal Schuster, Adam Fisch, Jai Gupta, Mostafa Dehghani, Dara Bahri, Vinh Q. Tran, Yi Tay, and Donald Metzler. Confident adaptive language modeling. In *Advances in Neural Information Processing Systems*, volume 35, pages 17456–17472, 2022. doi: 10.52202/068431-1269. URL https://proceedings.neurips.cc/paper_files/paper/2022/hash/6fac9e316a4ae75ea244ddcef1982c71-Abstract-Conference.html.

Juyun Wee, Minjae Park, and Jaeho Lee. Prompt-based depth pruning of large language models. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 65936–65948. PMLR, 2025. URL https://proceedings.mlr.press/v267/wee25a.html.

Ji Xin, Raphael Tang, Jaejun Lee, Yaoliang Yu, and Jimmy Lin. DeeBERT: Dynamic early exiting for accelerating BERT inference. In *Proceedings of the 58th Annual*

Meeting of the Association for Computational Linguistics, pages 2246–2251. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-main.204. URL https://aclanthology.org/2020.acl-main.204/.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=SkeHuCVFDr.