PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

SEQUENCE-LEVEL ROUTING FOR EFFICIENT QWEN3-0.6B INFERENCE IN INDONESIAN NEWS SUMMARIZATION

JOSEPH GREFFEN KOMALA
23/519909/PA/22318

PROGRAM STUDI [ISI NAMA PROGRAM STUDI]
DEPARTEMEN [ISI NAMA DEPARTEMEN]
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

TAHUN

PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

SEQUENCE-LEVEL ROUTING FOR EFFICIENT QWEN3-0.6B INFERENCE IN INDONESIAN NEWS SUMMARIZATION

Usulan Penelitian



JOSEPH GREFFEN KOMALA
23/519909/PA/22318

PROGRAM STUDI [ISI NAMA PROGRAM STUDI]
DEPERTEMEN [ISI NAMA DEPARTEMEN]
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

TAHUN

HALAMAN PENGESAHAN

PROPOSAL TUGAS AKHIR

SEQUENCE-LEVEL ROUTING UNTUK EFISIENSI INFERENSI QWEN3-0.6B PADA PERINGKASAN BERITA BAHASA INDONESIA

Telah dipersiapkan dan disusun oleh

JOSEPH GREFFEN KOMALA
23/519909/PA/22318

Telah dipertahankan di depan Tim Penguji
pada tanggal TANGGAL UJIAN BELUM DITETAPKAN

Susunan Tim Penguji

NAMA DOSEN PEMBIMBING
Pembimbing

NAMA DOSEN PENGUJI 1
Ketua Penguji

NAMA DOSEN PENGUJI 2
Anggota Penguji

DAFTAR ISI

Halaman Judul i

Halaman Pengesahan ii

INTISARI v

ABSTRACT vi

I PENDAHULUAN 1

1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Batasan Masalah 3
1.3.1 Cakupan Penelitian 3
1.3.2 Pengolahan dan Pemilihan Data 5
1.3.3 Lingkungan Penelitian 5
1.4 Tujuan Penelitian 6
1.5 Manfaat Penelitian 6
1.6 Sistematika Penulisan 6

II PENELITIAN TERKAIT 7

2.1 Efisiensi Inferensi dan Komputasi Adaptif 7
2.2 Pelompatan Lapisan Statis dan Routing Adaptif 8
2.3 Peringkasan Berita Bahasa Indonesia dan XL-Sum 9
2.4 Evaluasi Otomatis Peringkasan 9
2.5 Posisi Penelitian 9

III METODE DAN RANCANGAN PENELITIAN 11

3.1 Deskripsi Umum Penelitian 11
3.2 Model dan Data Penelitian 11
3.2.1 Model 11
3.2.2 Dataset XL-Sum Bahasa Indonesia 12
3.3 Tahapan Penelitian 13
3.4 Perancangan Sistem 14
3.4.1 Arsitektur Sistem 14

3.4.2 Keputusan Routing dan Pelatihan Router 16
3.4.3 Bagan Alir Metodologi 19
3.5 Rancangan Evaluasi 19
3.5.1 Metode Pembanding 19
3.5.2 Pemeriksaan Implementasi 20
3.5.3 Kualitas Ringkasan 20
3.5.4 Waktu Inferensi 21
3.6 Lingkungan Penelitian 21

IV JADWAL PENELITIAN **23**
4.1 Penyusunan Jadwal 23

INTISARI

Sequence-Level Routing untuk Efisiensi Inferensi Qwen3-0.6B pada Peringkasan Berita Bahasa Indonesia

Oleh

Joseph Greffen Komala
23/519909/PA/22318

Penelitian ini akan mengukur hubungan antara kualitas ringkasan dan efisiensi inferensi Qwen3-0.6B pada tugas peringkasan berita bahasa Indonesia menggunakan XL-Sum subset Indonesia. Mekanisme yang dikaji adalah pemilihan jalur eksekusi satu kali untuk setiap urutan masukan dan keluaran (*sequence-level routing*). Dari 28 lapisan model, lima kelompok tengah dapat dijalankan atau dilewati; kelompok pertama dan terakhir selalu dijalankan. Sebuah router menggunakan rata-rata vektor representasi internal token artikel setelah kelompok pertama untuk menentukan keputusan tersebut. Keputusan yang sama dipakai selama sisa pemrosesan prompt dan seluruh pembentukan token keluaran. Pelatihan dilakukan dalam dua tahap: router dilatih saat parameter Qwen dibekukan, kemudian router dibekukan dan adapter *Low-Rank Adaptation* (LoRA) dilatih untuk mengompensasi dampak pelompatan lapisan. Target router dibuat dari pencarian bertahap yang membandingkan kerugian prediksi token dengan proporsi kelompok lapisan yang aktif. Evaluasi membandingkan model penuh, pelompatan statis, dan routing adaptif dengan pelatihan LoRA yang setara, serta router tanpa LoRA sebagai kontrol. Kualitas dinilai secara otomatis menggunakan skor F1 pada ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. Skor F1 dihitung per artikel, dirata-ratakan secara terpisah untuk setiap metrik, lalu dilaporkan tanpa digabung menjadi satu skor. Efisiensi dinilai dari waktu total per artikel, termasuk biaya router, waktu pemrosesan prompt, waktu pembentukan keluaran, dan jumlah token keluaran. Penelitian ini tidak mengasumsikan bahwa routing akan unggul. Eksperimen menggunakan 1.000 artikel latih, 200 artikel validasi, dan 300 artikel uji pada laptop lokal; penelitian direncanakan berlangsung selama empat bulan.

ABSTRACT

Sequence-Level Routing for Efficient Qwen3-0.6B Inference in Indonesian News Summarization

By

Joseph Greffen Komala
23/519909/PA/22318

This study will measure the relationship between summary quality and inference efficiency for Qwen3-0.6B on Indonesian news summarization using the Indonesian subset of XL-Sum. It will examine sequence-level routing, which selects an execution path once for each input-and-output sequence. The model's 28 layers will be divided into seven consecutive groups of four. The first and last groups will always run, while a router will decide whether to run or skip each of the five middle groups. The router will use the mean internal representation of article tokens after the first group, and its decisions will remain fixed for the rest of prompt processing and all output-token generation. Training will use two stages: first, train the router while Qwen remains frozen; then freeze the router and train Low-Rank Adaptation (LoRA) adapters to compensate for layer skipping. Router targets will be produced by a greedy search balancing teacher-forced token prediction loss against the proportion of active middle groups. Evaluation will compare full-model, static-skipping, and adaptive-routing variants trained with LoRA, as well as routing without LoRA as a control. Quality will be assessed automatically using ROUGE-1, ROUGE-2, ROUGE-L, and BERTScore F1, calculated per article and averaged separately for each metric. Efficiency measures will include total time per article, router overhead, prompt-processing time, output-generation time, and output length. The study will not assume that routing will outperform the alternatives. The experiment will use 1,000 training articles, 200 validation articles, and 300 test articles on the local laptop; the study is planned to last four months.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Model bahasa menghasilkan teks sedikit demi sedikit dalam satuan yang disebut token (potongan teks). Pada setiap langkah inferensi, yaitu saat model digunakan untuk menghasilkan keluaran, model menghitung representasi melalui lapisan-lapisan Transformer, sebuah arsitektur jaringan saraf, sebelum memilih token berikutnya. Penghitungan berulang ini dapat membuat proses inferensi memerlukan waktu dan komputasi yang besar. FiRST, misalnya, mengkaji pengurangan waktu inferensi dengan melewati sebagian lapisan berdasarkan masukan [Jain et al., 2025]. Namun, pengurangan komputasi perlu dinilai bersama perubahan kualitas teks yang dihasilkan.

Salah satu cara mengurangi penghitungan tersebut adalah *layer skipping*, yaitu melewati lapisan tertentu saat model menghasilkan keluaran. Pada strategi statis, lapisan yang dijalankan sama untuk semua masukan. Pada strategi adaptif, keputusan lapisan dapat bergantung pada isi masukan. PuDDing menggunakan router, yaitu komponen ringan yang memilih lapisan untuk dijalankan, berdasarkan prompt (teks masukan yang berisi instruksi dan bahan untuk diproses) [Wee et al., 2025]. Hasil PuDDing pada tugas penalaran akal sehat yang diuji dalam penelitian tersebut menjadi bukti bagi pendekatan pemilihan adaptif pada tugas-tugas itu, tetapi tidak memastikan hasil yang sama pada peringkasan berita bahasa Indonesia.

Penelitian ini akan mengkaji pemilihan jalur eksekusi pada tingkat urutan masukan dan keluaran (*sequence-level routing*). Router akan membaca representasi prompt satu kali dan menentukan apakah setiap kelompok lapisan tengah dijalankan atau dilewati. Keputusan yang sama dipertahankan selama sisa pemrosesan prompt dan seluruh proses pembentukan token keluaran (*decoding*). Dengan demikian, jalur eksekusi tidak ditentukan ulang untuk setiap token keluaran. Pelatihan dilakukan dalam dua tahap sebagaimana gagasan FiRST: pertama, parameter model utama dibekukan dan hanya router yang dilatih; kedua, router dibekukan dan adapter Low-Rank Adaptation (LoRA) dilatih pada modul attention dan FFN untuk mengompensasi penurunan kualitas akibat pelompatan lapisan [Jain et al., 2025]. Target router dibuat dari ringkasan acuan melalui pengukuran kerugian prediksi token,

kemudian router dilatih untuk memprediksi target keputusan tersebut.

Model utama (*backbone*) yang digunakan adalah Qwen3-0.6B, yaitu model bahasa kausal yang memprediksi token berikutnya berdasarkan teks sebelumnya, dengan ukuran nominal 0,6 miliar parameter dan 28 lapisan [Qwen Team, 2025]. Tugas penelitian adalah peringkasan berita bahasa Indonesia menggunakan bagian berbahasa Indonesia dari XL-Sum. Dataset XL-Sum berisi pasangan artikel dan ringkasan yang disiapkan untuk penelitian peringkasan abstraktif, yaitu peringkasan yang merumuskan kembali informasi penting dengan kalimat baru [Hasan et al., 2021]. Ringkasan acuan digunakan saat membentuk target pelatihan router, tetapi tidak diberikan kepada router sebagai masukan saat inferensi.

Jumlah lapisan yang dilewati saja belum menunjukkan manfaat praktis. Router menambah pekerjaan komputasi untuk membaca representasi prompt dan menentukan jalur. Karena itu, penelitian ini akan mengukur waktu inferensi aktual, termasuk biaya tambahan router, dan menilai perubahan kualitas ringkasan. Analisis tersebut diperlukan untuk melihat apakah penghematan waktu sebanding dengan perubahan kualitas.

Evaluasi akan membandingkan model penuh, pelompatan lapisan statis, dan router adaptif dengan adapter LoRA yang dilatih di bawah masing-masing kondisi. Router tanpa LoRA dipertahankan sebagai kontrol untuk mengukur kontribusi tahap kompensasi LoRA. Pola statis dipilih menggunakan data validasi dan diterapkan pada semua artikel. Efisiensi utama dibandingkan menggunakan waktu inferensi aktual pada lingkungan dan pengaturan yang sama; jumlah lapisan aktif dan panjang keluaran dilaporkan sebagai informasi tambahan. Penelitian tidak mengasumsikan routing atau LoRA akan lebih unggul. Hasil evaluasi akan digunakan untuk memisahkan dampak routing dan adaptasi LoRA pada kualitas serta biaya inferensi. Kontribusi penelitian akan dirumuskan lebih lanjut setelah kajian literatur dilengkapi dan dibahas bersama dosen pembimbing.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, penelitian ini mengajukan pertanyaan berikut.

1. Bagaimana pengaruh sequence-level routing terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B pada XL-Sum Indonesia?

2. Apakah routing adaptif dengan LoRA memberikan trade-off kualitas–efisiensi yang lebih baik daripada pelompatan lapisan statis dan model penuh dengan LoRA, dan bagaimana kontribusi LoRA dibandingkan dengan router tanpa LoRA?

1.3 Batasan Masalah

1.3.1 Cakupan Penelitian

Penelitian ini dibatasi pada aspek-aspek berikut.

1. Model yang digunakan adalah Qwen3-0.6B, sebuah model bahasa kecil berbasis decoder (*decoder-only small language model*, SLM).

2. Tugas penelitian adalah peringkasan berita berbahasa Indonesia menggunakan subset Indonesia dari XL-Sum.

3. Mekanisme yang ditambahkan terdiri atas router ringan dan pelaksanaan kelompok lapisan secara kondisional. Sebanyak 28 lapisan dibagi menjadi tujuh kelompok berurutan, masing-masing berisi empat lapisan. Kelompok pertama dan terakhir selalu dijalankan. Setiap kelompok tengah dapat dijalankan atau dilewati; jumlah lapisan aktif tidak ditetapkan sama untuk setiap artikel.

4. Router menggunakan rata-rata vektor representasi internal (*hidden state*) token artikel setelah kelompok pertama. Token instruksi, token khusus, dan padding tidak disertakan dalam rata-rata. Sebuah jaringan perceptron multilapis (*multilayer perceptron*, MLP) dengan 64 unit pada satu lapisan tersembunyi, aktivasi ReLU, dan lima keluaran sigmoid menghasilkan keputusan untuk kelompok tengah. Keluaran sigmoid lebih besar atau sama dengan 0,5 diubah menjadi keputusan aktif, sedangkan keluaran di bawah 0,5 diubah menjadi keputusan lewati. Jalur dipilih berdasarkan prompt dan dipertahankan selama sisa pemrosesan prompt serta seluruh pembentukan token keluaran.

5. Pelatihan terdiri atas dua tahap. Pada tahap pertama, parameter Qwen dibekukan dan hanya parameter router yang diperbarui. Target router dibuat pada data latih melalui pencarian bertahap yang menyeimbangkan kerugian prediksi token dan proporsi kelompok tengah aktif; router dilatih menggunakan

fungsi kerugian klasifikasi biner. Pada tahap kedua, bobot router dibekukan dan adapter LoRA dilatih pada modul attention dan FFN di seluruh lapisan Qwen menggunakan data latih. Untuk routing adaptif, fungsi objektif tahap LoRA mencakup penalti agar tingkat pelompatan tidak hilang akibat perubahan representasi. Konfigurasi adapter dan optimisasi yang belum ditetapkan akan ditentukan atau diverifikasi menggunakan data validasi.

6. Evaluasi mencakup model penuh+LoRA, pelompatan statis+LoRA, routing adaptif+LoRA, serta routing adaptif tanpa LoRA sebagai kontrol ablation. Satu pola static dipilih menggunakan data validasi dan diterapkan pada semua artikel. Perbandingan kualitas dan efisiensi menggunakan waktu inferensi aktual; jumlah lapisan aktif dan panjang keluaran dilaporkan sebagai informasi tambahan.

7. Kualitas ringkasan dinilai sepenuhnya secara otomatis menggunakan skor F1 pada ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. ROUGE mengukur kecocokan kata dan urutannya; BERTScore membandingkan representasi kontekstual teks. Skor F1 menggabungkan presisi dan cakupan. F1 dihitung untuk setiap artikel, lalu dirata-ratakan secara terpisah untuk tiap metrik; keempat skor dilaporkan sendiri-sendiri. Tidak dilakukan penilaian manual atau pemeriksaan faktualitas manual pada sampel. Efisiensi dinilai melalui waktu total per artikel, waktu pemrosesan prompt, waktu pembentukan keluaran, dan jumlah token keluaran. Pengukuran menggunakan ukuran batch satu, pemanasan eksekusi (*warm-up*), dan pengulangan. Semua metode menggunakan mode non-thinking, yaitu mode yang mencegah Qwen menghasilkan teks penalaran sebelum jawaban akhir, dan konfigurasi *greedy decoding* yang sama: `do_sample=False` dan `num_beams=1`. Perangkat dan presisi numerik juga akan disamakan.

8. Batas jendela konteks eksperimen adalah 4.096 token untuk masukan dan keluaran secara gabungan. Keluaran dibatasi hingga maksimum 256 token, sehingga masukan dapat memuat paling banyak 3.840 token, termasuk instruksi dan format chat. Generasi berhenti saat model mengeluarkan token akhir respons sesuai konfigurasi model atau mencapai 256 token. Token akhir respons termasuk dalam batas 256 token dan tidak ditetapkan panjang minimum. Batas dan aturan penghentian ini sama untuk seluruh metode.

1.3.2 Pengolahan dan Pemilihan Data

Sebelum pemrosesan, spasi dan baris kosong dihapus hanya dari awal dan akhir artikel serta ringkasan acuan. Huruf besar, tanda baca, spasi di antara kata, dan isi teks lainnya dipertahankan. Pasangan artikel–ringkasan dikeluarkan jika salah satu teks kosong setelah pembersihan ini. Aturan tersebut berlaku pada data latih (*train*), validasi (*validation*), dan uji (*test*); jumlah pasangan kosong yang dikeluarkan akan dicatat.

Artikel dianggap duplikat jika teksnya sama persis setelah pembersihan. Dalam satu bagian data (*split*), kemunculan pertama menurut urutan asli dataset dipertahankan bersama ringkasan acuannya. Jika artikel yang sama muncul pada beberapa split, pasangan pada data uji diprioritaskan, diikuti data validasi lalu data latih. Salinan pada split lain dikeluarkan dan tidak dipindahkan. Identitas serta jumlah pasangan yang dikeluarkan akan dicatat.

Artikel dikeluarkan jika prompt lengkap yang memuat artikel utuh melebihi 3.840 token menurut tokenizer Qwen3-0.6B. Prompt mencakup instruksi dan format chat; artikel tidak dipotong. Ringkasan acuan juga dikeluarkan jika melebihi 256 token, termasuk token akhir respons menurut tokenizer yang sama. Ringkasan tidak dipotong. Kedua batas diterapkan pada seluruh split. Himpunan artikel evaluasi akan sama untuk semua metode. Jumlah artikel yang dikeluarkan karena batas panjang dan jumlah yang tersisa pada setiap split akan dicatat.

Sampel dipilih secara acak tanpa pengembalian pada setiap split setelah pembersihan, penyaringan, dan penghapusan duplikasi. Sebanyak 1.000 artikel dipilih untuk data latih, 200 artikel untuk data validasi, dan 300 artikel untuk data uji. Pemilihan memakai seed tetap 42. Identitas sampel terpilih akan disimpan, dan semua metode akan menggunakan subset evaluasi yang sama.

1.3.3 Lingkungan Penelitian

Penelitian akan dilakukan pada laptop lokal dengan CPU AMD Ryzen 3 5300U (empat inti dan delapan thread). Sistem memiliki RAM sekitar 9,1 GiB dan grafis Radeon terintegrasi. Eksperimen menggunakan CPU, presisi FP32, dan ukuran batch satu. Semua metode pembanding akan diukur pada lingkungan dan pengaturan perangkat yang sama. Versi perangkat lunak dan revisi model yang digunakan akan dicatat pada pelaksanaan eksperimen.

Eksperimen akan menggunakan 1.000 artikel latih, 200 artikel validasi, dan

300 artikel uji setelah pembersihan, penyaringan, dan penghapusan duplikasi. Pengukuran waktu menggunakan tiga kali pemanasan dan lima kali pengulangan; hasil utama dilaporkan sebagai median. Penelitian direncanakan berlangsung selama empat bulan. Versi perangkat lunak dan jumlah pasangan yang tersisa setelah penyaringan akan dicatat sebagai informasi reproduksi.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. menganalisis pengaruh sequence-level routing terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B pada XL-Sum Indonesia; dan
2. membandingkan keseimbangan kualitas dan efisiensi (*trade-off*) routing adaptif+LoRA dengan static skipping+LoRA dan model penuh+LoRA, serta mengukur kontribusi LoRA melalui kontrol router tanpa LoRA.

1.5 Manfaat Penelitian

Secara akademik, penelitian ini diharapkan memberikan bukti empiris tentang perilaku routing adaptif pada Qwen3-0.6B untuk peringkasan berita bahasa Indonesia. Hasilnya akan menunjukkan hubungan antara kelompok lapisan yang dijalankan, kualitas ringkasan, dan waktu inferensi pada rancangan yang diuji. Temuan dan keterbatasannya dapat membantu merumuskan pertanyaan untuk penelitian lanjutan.

Secara praktis, dokumentasi implementasi dan protokol evaluasi diharapkan membantu peneliti lain menguji pelaksanaan lapisan secara kondisional pada model ini. Hasil penelitian dapat digunakan untuk menilai penghematan waktu inferensi beserta perubahan kualitas ringkasan, tanpa menganggap bahwa melewati lapisan selalu mempercepat proses.

1.6 Sistematika Penulisan

Proposal ini terdiri atas empat bab. Bab I menjelaskan latar belakang, rumusan masalah, batasan, tujuan, dan manfaat penelitian. Bab II mengulas penelitian terkait dan menjelaskan posisi penelitian ini. Bab III memaparkan metode, rancangan sistem, tahapan penelitian, dan rencana evaluasi. Bab IV menjelaskan jadwal penelitian selama empat bulan dalam bentuk bagan berbasis bulan.

BAB II

PENELITIAN TERKAIT

2.1 Efisiensi Inferensi dan Komputasi Adaptif

Model Transformer berukuran besar memerlukan penghitungan berulang pada banyak lapisan. Pada model decoder-only, seluruh atau sebagian besar lapisan tersebut dilalui berulang kali untuk setiap token keluaran. Biaya ini menjadi penting pada perangkat dengan sumber daya terbatas, sehingga penelitian efisiensi inferensi berusaha mengurangi penghitungan tanpa mengubah tugas yang harus diselesaikan model.

Salah satu pendekatan awal adalah membuat model mampu menggunakan kedalaman yang lebih pendek saat inferensi. LayerDrop menggunakan *structured dropout* selama pelatihan agar subjaringan dengan kedalaman berbeda dapat digunakan pada saat inferensi dengan penurunan kinerja yang terbatas [Fan et al., 2020]. Pendekatan *early exit* mengambil keputusan untuk berhenti pada lapisan antara ketika keluaran dianggap telah cukup baik. DeeBERT, misalnya, menambahkan titik keluar pada beberapa lapisan BERT sehingga sebagian masukan tidak perlu melewati seluruh jaringan [Xin et al., 2020].

Pada pembangkitan autoregresif, keputusan komputasi dapat dibuat pada tingkat urutan, token, atau lapisan. Confident Adaptive Language Modeling (CALM) mengalokasikan komputasi secara adaptif untuk setiap masukan dan langkah pembangkitan token. Pendekatan tersebut menunjukkan bahwa keputusan pada tingkat token memerlukan penanganan khusus terhadap dependensi antartoken dan representasi yang tidak dihitung pada langkah sebelumnya [Schuster et al., 2022]. LayerSkip juga mengkaji efisiensi model bahasa autoregresif melalui pelatihan dengan *layer dropout* dan *early-exit loss*, kemudian menggunakan keluaran lapisan awal untuk *self-speculative decoding* [Elhoushi et al., 2024].

Literatur tersebut menunjukkan bahwa pengurangan kedalaman dapat menurunkan biaya inferensi, tetapi setiap pendekatan membuat keputusan pada tingkat dan kondisi yang berbeda. Sebagian pendekatan juga memerlukan perubahan atau pelatihan ulang pada model utama. Penelitian ini mempertahankan bobot dasar Qwen3-0.6B dan melatih router, lalu menggunakan adapter LoRA sebagai tahap kompensasi terpisah.

2.2 Pelompatan Lapisan Statis dan Routing Adaptif

Pelompatan lapisan statis menjalankan pola lapisan yang sama untuk semua masukan. Strategi ini sederhana dan mudah direproduksi, tetapi tidak dapat menyesuaikan jumlah komputasi dengan isi artikel. Sebaliknya, routing adaptif memilih jalur eksekusi berdasarkan karakteristik masukan. Perbedaan ini penting karena artikel dengan tingkat kesulitan dan struktur informasi yang berbeda belum tentu memerlukan jalur komputasi yang sama.

PuDDing menggunakan prompt untuk memilih pola kedalaman dari beberapa pola lapisan yang telah disiapkan. Hasilnya menunjukkan potensi routing berbasis prompt untuk mengurangi komputasi, tetapi pendekatan tersebut memilih di antara pola yang telah ditentukan dan dievaluasi pada tugas penalaran akal sehat [Wee et al., 2025]. Penelitian ini menggunakan keluaran biner terpisah untuk setiap kelompok lapisan tengah. Dengan demikian, pola route tidak diperlakukan sebagai kelas dengan identitas tertentu dan jumlah lapisan aktif dapat berbeda antarartikel.

FiRST memperluas gagasan routing berbasis prompt dengan router khusus pada lapisan dan keputusan yang dibuat pada tahap *prefill*, kemudian dipakai selama proses pembentukan token keluaran. FiRST melatih router lebih dahulu dengan backbone beku, lalu membekukan router dan melatih adapter LoRA pada modul attention dan FFN untuk memulihkan kualitas setelah pelompatan lapisan [Jain et al., 2025]. Penelitian ini mengadopsi pola pelatihan dua tahap tersebut, tetapi tetap menggunakan satu router pada tingkat kelompok lapisan, bukan router terpisah untuk setiap lapisan. Target router penelitian ini dibentuk melalui pencarian bertahap berdasarkan kerugian prediksi token dan proporsi kelompok aktif.

Beberapa penelitian juga menunjukkan bahwa pengurangan komputasi pada model autoregresif harus memperhatikan cara representasi dan *key-value cache* dikelola. FFN-SkipLLM melaporkan bahwa strategi *early exit* yang tidak tepat dapat berkaitan dengan keruntuhan generasi, halusinasi, dan penurunan kualitas, lalu mengusulkan pelompatan blok feed-forward yang tidak memerlukan penanganan KV cache dengan cara yang sama [Jaiswal et al., 2024]. Oleh karena itu, penelitian ini memasukkan pemeriksaan bahwa lapisan yang dilewati benar-benar tidak dieksekusi, route tidak berubah selama decoding, dan KV cache konsisten. Efisiensi utama juga diukur menggunakan waktu inferensi aktual, bukan hanya jumlah lapisan yang dilewati.

2.3 Peringkasan Berita Bahasa Indonesia dan XL-Sum

XL-Sum merupakan dataset peringkasan abstraktif multibahasa yang berisi pasangan artikel berita dan ringkasan acuan pada 44 bahasa, termasuk bahasa Indonesia [Hasan et al., 2021]. Dataset ini sesuai dengan penelitian karena menyediakan pasangan masukan dan keluaran yang dapat digunakan untuk membentuk target pelatihan router serta mengevaluasi ringkasan hasil generasi. Penelitian ini hanya menggunakan konfigurasi bahasa Indonesia dan menerapkan satu prosedur pemrosesan data pada seluruh metode pembanding.

Model yang digunakan adalah Qwen3-0.6B, model bahasa kausal dengan 28 lapisan [Qwen Team, 2025]. Bobot dasar model dipertahankan, sedangkan adapter LoRA menjadi parameter yang dilatih setelah pelatihan router. Perbandingan meliputi adapter LoRA pada model penuh, pola statis, dan routing adaptif, serta routing tanpa LoRA sebagai kontrol untuk mengukur kontribusi kompensasi LoRA.

2.4 Evaluasi Otomatis Peringkasan

ROUGE merupakan keluarga metrik yang membandingkan tumpang tindih unit teks antara ringkasan keluaran dan ringkasan acuan. ROUGE-N mengukur kecocokan n-gram, sedangkan ROUGE-L menggunakan subsekuens umum terpanjang [Lin, 2004]. Penelitian ini menggunakan ROUGE-1, ROUGE-2, dan ROUGE-L untuk menangkap kecocokan kata, pasangan kata berurutan, dan struktur urutan teks.

BERTScore melengkapi ROUGE dengan membandingkan representasi kontekstual token menggunakan kemiripan kosinus [Zhang et al., 2020]. Metrik ini dapat menangkap kemiripan makna yang tidak selalu menghasilkan tumpang tindih kata secara langsung. Namun, kedua kelompok metrik tersebut tetap merupakan ukuran kecocokan terhadap acuan. Forde et al. menunjukkan bahwa metrik otomatis dapat kurang andal untuk menilai kualitas peringkasan multibahasa, dengan masalah yang lebih besar pada bahasa Indonesia [Forde et al., 2024]. Karena itu, penelitian ini menggunakan beberapa metrik secara terpisah dan tidak menyimpulkan bahwa skor tersebut menjamin faktualitas atau kualitas ringkasan secara menyeluruh.

2.5 Posisi Penelitian

Penelitian terdahulu telah menunjukkan beberapa cara mengurangi komputasi Transformer, mulai dari pelatihan agar model tahan terhadap kedalaman yang lebih

pendek, *early exit*, hingga routing berbasis prompt. Namun, pendekatan tersebut berbeda dalam tingkat keputusan, kebutuhan perubahan model utama, tugas evaluasi, dan cara pengukuran efisiensinya.

Posisi penelitian ini adalah menguji *sequence-level routing* pada Qwen3-0.6B untuk peringkasan berita bahasa Indonesia menggunakan XL-Sum. Router membaca representasi token artikel setelah kelompok pertama dan memilih secara biner apakah lima kelompok lapisan tengah dijalankan atau dilewati. Keputusan yang sama dipertahankan selama sisa pemrosesan prompt dan seluruh decoding. Setelah router dilatih dengan parameter Qwen dibekukan, router dipertahankan tetap dan LoRA dilatih sebagai tahap kompensasi. Router tanpa LoRA digunakan sebagai ablation.

Penelitian ini membandingkan routing adaptif dengan model penuh dan satu pola pelompatan statis yang dipilih menggunakan data validasi, dengan pelatihan LoRA yang diterapkan pada tiap kondisi. Perbandingan tidak hanya menggunakan jumlah lapisan aktif, tetapi juga waktu inferensi aktual pada perangkat dan pengaturan yang sama, termasuk waktu adapter, biaya router, *prefill*, dan *decoding*. Dengan demikian, penelitian menguji trade-off kualitas–efisiensi routing adaptif serta kontribusi LoRA pada tugas dan lingkungan yang ditentukan. Penelitian ini tidak mengklaim bahwa penggunaan router, pembagian kelompok lapisan, atau model Qwen3-0.6B tersebut merupakan penerapan pertama.

BAB III

METODE DAN RANCANGAN PENELITIAN

3.1 Deskripsi Umum Penelitian

Penelitian ini dirancang sebagai eksperimen untuk mengukur pengaruh pelompatan kelompok lapisan terhadap kualitas ringkasan dan waktu inferensi Qwen3-0.6B. Model menerima artikel berita berbahasa Indonesia dan menghasilkan ringkasan. Sebuah router ringan akan menentukan kelompok lapisan yang dijalankan berdasarkan representasi artikel pada prompt. Keputusan tersebut dibuat satu kali untuk setiap artikel, lalu digunakan selama pemrosesan prompt dan pembentukan seluruh token ringkasan.

Kinerja metode routing akan dibandingkan dengan dua acuan. Acuan pertama adalah Qwen3-0.6B yang menjalankan seluruh lapisannya. Acuan kedua adalah pelompatan statis, yaitu penggunaan satu pola kelompok lapisan yang sama untuk semua artikel. Kualitas keluaran akan dinilai menggunakan ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. Efisiensi utama akan dinilai dari waktu inferensi yang diukur pada perangkat dan pengaturan yang sama. Jumlah lapisan aktif dilaporkan sebagai informasi tambahan.

3.2 Model dan Data Penelitian

3.2.1 Model

Model yang digunakan adalah Qwen3-0.6B dengan identitas `Qwen/Qwen3-0.6B`. Model ini memiliki 28 lapisan transformer [Qwen Team, 2025]. Untuk keperluan routing, lapisan dibagi menjadi tujuh kelompok berurutan yang masing-masing berisi empat lapisan. Jika lapisan diberi nomor dari satu, kelompok G_i mencakup lapisan $4i - 3$ sampai dengan $4i$, untuk $i = 1, \ldots, 7$.

Kelompok pertama (G_1) dan kelompok terakhir (G_7) selalu dijalankan. Router menentukan apakah masing-masing dari lima kelompok di antaranya (G_2 sampai G_6) dijalankan atau dilewati. Ketentuan untuk G_1 dan G_7 merupakan bagian dari rancangan eksperimen; penelitian ini tidak menganggap kedua kelompok tersebut telah terbukti lebih penting daripada kelompok lainnya.

Model dijalankan dalam mode non-thinking. Pengujian menggunakan pemili-

han token dengan skor tertinggi pada setiap langkah, tanpa pengambilan sampel acak, dengan pengaturan `do_sample=False` dan `num_beams=1`. Panjang seluruh urutan dibatasi hingga 4.096 token. Prompt, termasuk instruksi dan format chat, paling panjang 3.840 token, sedangkan ringkasan keluaran dibatasi hingga 256 token. Pembentukan ringkasan berhenti ketika model menghasilkan token akhir respons atau ketika batas keluaran tercapai. Batas dan aturan ini digunakan sama untuk seluruh metode.

Versi bobot model, tokenizer, dan perangkat lunak yang digunakan akan dicatat sebelum evaluasi agar konfigurasi penelitian dapat dilaporkan dengan jelas.

3.2.2 Dataset XL-Sum Bahasa Indonesia

Data penelitian berasal dari XL-Sum konfigurasi bahasa Indonesia [CSE BUET NLP Group, t.t.a]. Dataset ini berisi artikel berita dan ringkasan acuannya. Artikel digunakan sebagai masukan model, sedangkan ringkasan acuan digunakan untuk menilai hasil dan menyiapkan data pelatihan router. Data dibagi menjadi bagian pelatihan, validasi, dan pengujian sesuai pembagian yang tersedia pada dataset [CSE BUET NLP Group, t.t.b]. Data pengujian hanya digunakan untuk evaluasi akhir, bukan untuk melatih router atau memilih konfigurasi.

Jumlah artikel yang digunakan pada setiap bagian belum ditetapkan. Jumlah tersebut akan dipilih setelah waktu pemrosesan dan kebutuhan memori diukur. Jika hanya sebagian data digunakan, artikel dipilih secara acak tanpa pengembalian pada setiap bagian dengan seed 42. Identitas artikel yang terpilih akan disimpan, dan himpunan data uji yang sama akan digunakan untuk semua metode.

Pembersihan teks dan penghapusan duplikasi

Pembersihan hanya menghapus spasi dan baris kosong di awal serta akhir artikel dan ringkasan acuan. Huruf besar, tanda baca, spasi di antara kata, dan isi lainnya dipertahankan. Pasangan artikel dan ringkasan dikeluarkan apabila salah satunya kosong setelah pembersihan. Jumlah pasangan yang dikeluarkan dicatat.

Dua artikel dinyatakan duplikat apabila teksnya sama persis setelah pembersihan. Jika duplikasi terjadi pada bagian data yang sama, kemunculan pertama menurut urutan dataset dipertahankan beserta ringkasan acuannya. Jika artikel yang sama ditemukan pada lebih dari satu bagian data, pasangan pada data uji dipertahankan jika tersedia; jika tidak, pasangan pada data validasi dipertahankan daripada pasangan pada data latih. Salinan pada bagian lain dihapus dan tidak dipindahkan. Pemerik-

saan duplikasi dilakukan sebelum pemilihan sebagian data, dan jumlah serta identitas pasangan yang dihapus dicatat.

Pemeriksaan batas panjang

Prompt lengkap disusun dengan format yang dijelaskan pada bagian berikut, kemudian jumlah potongan teks (token) di dalamnya dihitung menggunakan tokenizer Qwen3-0.6B. Artikel dikeluarkan jika prompt lengkap melebihi 3.840 token. Artikel tidak dipotong. Ringkasan acuan juga dikeluarkan jika panjangnya melebihi 256 token, termasuk token akhir respons; ringkasan tidak dipotong. Aturan ini diterapkan pada data latih, validasi, dan uji. Pasangan prompt dan ringkasan acuan yang digunakan dalam pelatihan diperiksa agar jumlah token gabungannya tidak melebihi 4.096. Jumlah pasangan yang dikeluarkan karena batas panjang dan jumlah akhir pada setiap bagian data akan dicatat.

Format prompt

Instruksi dan artikel disampaikan sebagai pesan pengguna dalam format chat Qwen dengan mode non-thinking. Teks prompt yang digunakan adalah sebagai berikut. Penanda `{artikel}` diganti dengan teks artikel secara utuh.

> Ringkas artikel berita berikut dalam bahasa Indonesia. Pertahankan informasi utama dan jangan menambahkan informasi yang tidak terdapat dalam artikel.
>
> Artikel:
> `{artikel}`

Format tersebut digunakan untuk menyiapkan masukan pelatihan dan menghasilkan ringkasan dengan seluruh metode. Penghitungan batas masukan dilakukan setelah prompt disusun dalam format chat, termasuk penanda awal respons asisten.

3.3 Tahapan Penelitian

Penelitian akan dilaksanakan melalui tahapan berikut.

1. **Penyusunan protokol penelitian.** Kajian pustaka dan rancangan eksperimen dilengkapi. Parameter yang sudah ditetapkan dipisahkan dari parameter yang masih harus dipilih menggunakan data validasi atau ditetapkan sebelum evaluasi.

2. **Persiapan data dan model.** Data dibersihkan, diperiksa terhadap duplikasi dan batas panjang, lalu dibagi untuk pelatihan, validasi, dan pengujian. Prompt disusun dengan format yang telah ditetapkan. Versi model, tokenizer, dan perangkat lunak dicatat.

3. **Implementasi metode.** Router, eksekusi kelompok lapisan secara kondisional, model penuh, dan pelompatan statis diimplementasikan. Kesesuaian hasil ketika seluruh lapisan dijalankan serta konsistensi eksekusi saat kelompok dilewati akan diperiksa.

4. **Pelatihan dan pemilihan konfigurasi.** Target keputusan untuk router dibentuk dari data latih dengan membandingkan kerugian prediksi token dan proporsi kelompok tengah yang dijalankan. Selanjutnya, router dilatih dengan bobot Qwen dibekukan. Data validasi digunakan untuk memilih nilai penalti dan pola pelompatan statis.

5. **Evaluasi.** Metode dengan konfigurasi terpilih dijalankan pada data uji yang sama. Kualitas ringkasan, waktu inferensi, jumlah token keluaran, dan pola kelompok yang dipilih dicatat serta dibandingkan.

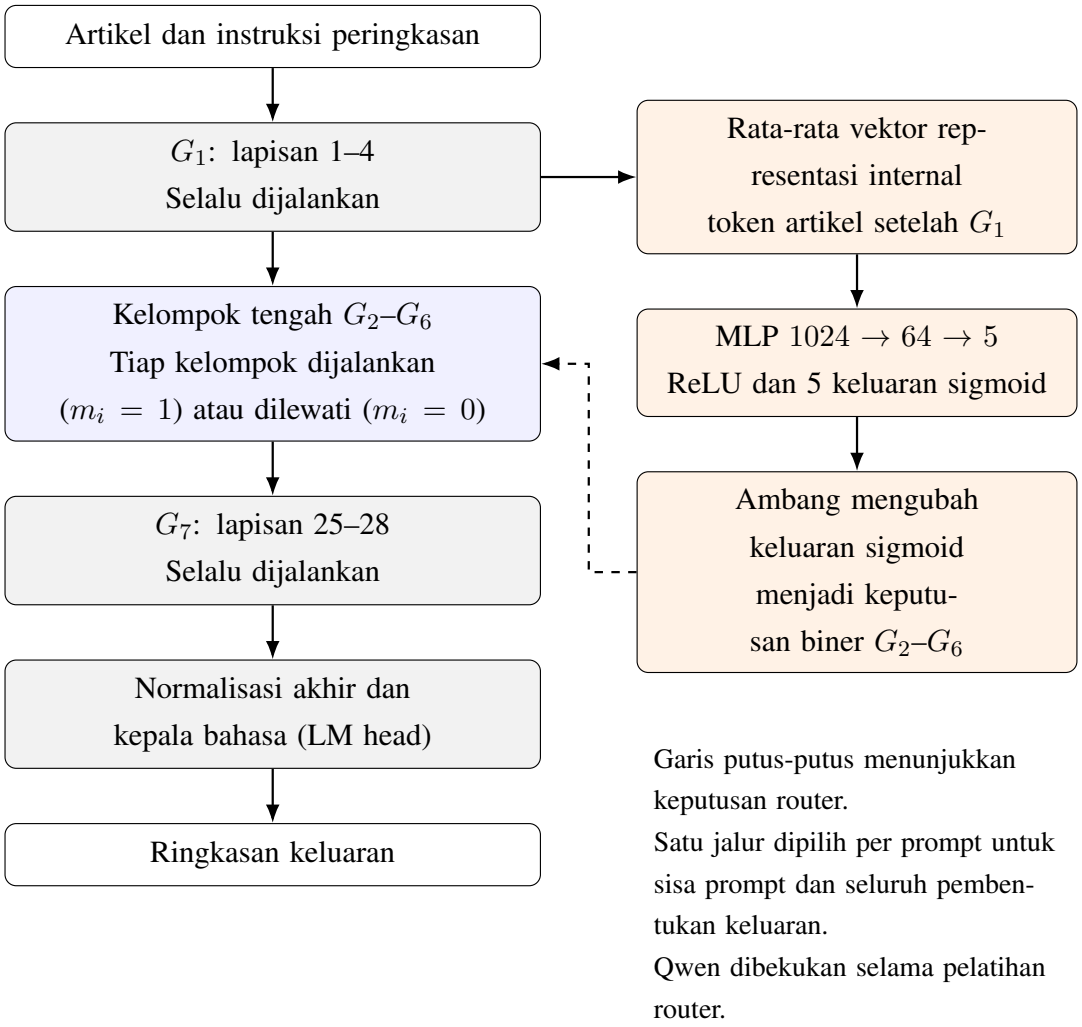
6. **Analisis dan penulisan.** Hasil perbandingan ditafsirkan sesuai metrik dan lingkungan pengujian. Rancangan, implementasi, hasil, serta keterbatasan penelitian didokumentasikan.

Pemeriksaan kebenaran implementasi merupakan bagian dari eksperimen utama, bukan tahap pilot yang terpisah. Implementasi routing dan evaluasinya merupakan pekerjaan yang direncanakan dalam proposal ini.

3.4 Perancangan Sistem

3.4.1 Arsitektur Sistem

Gambar 3.1 memperlihatkan alur pemrosesan artikel. Model terlebih dahulu menjalankan kelompok pertama. Keluaran dari kelompok tersebut digunakan untuk menghitung representasi artikel yang menjadi masukan router. Router menghasilkan lima keputusan: satu keputusan untuk setiap kelompok G_2 sampai G_6. Kelompok yang dipilih kemudian dijalankan sesuai urutan lapisan model, diikuti kelompok terakhir dan kepala bahasa untuk menghasilkan ringkasan.



Gambar 3.1: Arsitektur sequence-level routing pada Qwen3-0.6B.

Representasi artikel dihitung sebagai rata-rata representasi internal token artikel setelah kelompok pertama. Token instruksi, token khusus, dan padding tidak disertakan dalam perhitungan. Keluaran kelompok pertama yang telah dihitung untuk router digunakan kembali untuk melanjutkan pemrosesan prompt, sehingga kelompok tersebut tidak perlu dijalankan ulang. Setelah keputusan dibuat, pola kelompok yang dijalankan tetap sama selama sisa pemrosesan prompt dan seluruh pembentukan ringkasan. Penyimpanan nilai key dan value (KV cache), yang digunakan kembali saat model membentuk token berikutnya, disiapkan untuk lapisan yang dijalankan. Waktu untuk menghitung representasi dan menjalankan router termasuk dalam pengukuran waktu inferensi.

3.4.2 Keputusan Routing dan Pelatihan Router

Keputusan untuk setiap kelompok

Untuk setiap kelompok tengah G_i, dengan $i = 2, \ldots, 6$, router menghasilkan keputusan $m_i \in \{0, 1\}$. Nilai $m_i = 1$ berarti kelompok dijalankan, sedangkan $m_i = 0$ berarti kelompok dilewati. Dengan demikian, pola keputusan lengkap ditulis sebagai $(1, m_2, m_3, m_4, m_5, m_6, 1)$. Jumlah lapisan yang dijalankan dapat berbeda untuk setiap artikel, dengan perubahan sebanyak empat lapisan. Router membuat keputusan satu kali berdasarkan prompt dan tidak memilih ulang kelompok untuk setiap token ringkasan.

Bentuk dan masukan router

Router berupa jaringan saraf dengan satu lapisan tersembunyi berisi 64 unit dan fungsi aktivasi ReLU. Masukannya adalah representasi artikel berdimensi 1.024 setelah kelompok pertama, dan keluarannya terdiri atas lima nilai yang masing-masing mewakili satu kelompok tengah. Fungsi sigmoid mengubah setiap nilai keluaran menjadi angka antara nol dan satu. Nilai yang sama dengan atau lebih besar dari 0,5 menjadi keputusan untuk menjalankan kelompok; nilai di bawah 0,5 menjadi keputusan untuk melewatinya. Pada saat digunakan untuk membuat ringkasan, router hanya menerima representasi artikel dari prompt dan tidak menggunakan ringkasan acuan.

Pembentukan target pelatihan

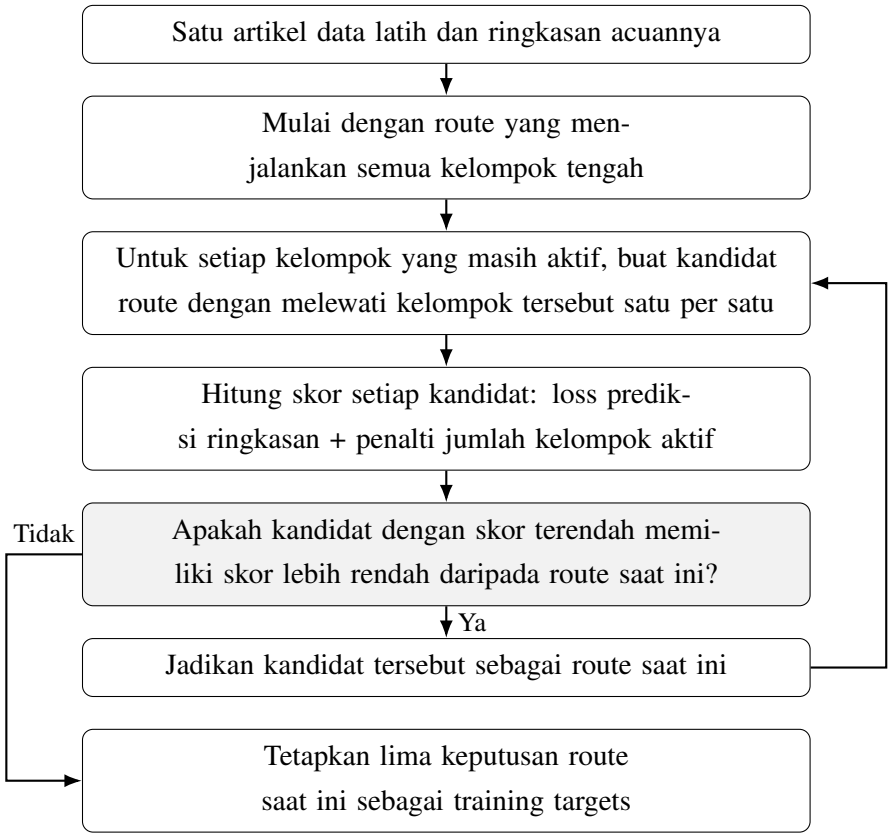
Sebelum router dilatih, perlu disiapkan contoh keputusan yang akan dipelajarinya. Contoh ini disebut *training targets*. Target dibuat untuk setiap artikel pada data latih dengan menggunakan artikel dan ringkasan acuannya. Ringkasan acuan membantu menilai apakah suatu pola kelompok lapisan menghasilkan prediksi yang mendekati ringkasan tersebut. Untuk penilaian ini, model menerima token ringkasan acuan sebelumnya sebagai masukan saat memprediksi token berikutnya. Cara tersebut disebut *teacher forcing*.

Setiap pola kelompok lapisan disebut *route*. Untuk menilai route, dihitung *loss*, yaitu nilai yang menunjukkan kesalahan prediksi token. Nilai loss yang lebih rendah berarti prediksi model lebih sesuai dengan ringkasan acuan. Skor route juga memperhitungkan jumlah kelompok tengah yang dijalankan:

$$J(m) = \mathrm{NLL}(m) + \lambda C(m), \qquad C(m) = \frac{m_2 + m_3 + m_4 + m_5 + m_6}{5}, \qquad (3.1)$$

dengan m sebagai route yang sedang dinilai dan $J(m)$ sebagai skor total route tersebut. Nilai $\mathrm{NLL}(m)$ adalah rata-rata kerugian prediksi token atau *negative log-likelihood* (NLL); nilai yang lebih rendah menunjukkan bahwa prediksi model lebih sesuai dengan ringkasan acuan. Nilai $C(m)$ menunjukkan proporsi kelompok tengah yang dijalankan. Sebagai contoh, jika tiga dari lima kelompok tengah dijalankan, maka $C(m) = 3/5 = 0{,}6$. Nilai λ adalah bobot yang mengatur pengaruh jumlah kelompok aktif terhadap skor. Karena semua kelompok berisi empat lapisan, proporsi kelompok aktif juga menunjukkan proporsi lapisan tengah yang dijalankan. Dengan demikian, $J(m)$ menggabungkan kerugian prediksi ringkasan dan jumlah kelompok aktif; route dengan skor $J(m)$ lebih rendah lebih dipilih.

Gambar 3.2 merangkum cara memilih route untuk satu artikel. Pencarian dimulai dari route yang menjalankan semua kelompok tengah. Pada setiap putaran, dibuat beberapa kandidat route dengan melewati satu kelompok aktif yang berbeda, lalu skor tiap kandidat dihitung. Jika skor terbaik lebih rendah daripada skor route saat ini, kandidat itu menjadi route baru dan pencarian diulangi. Jika tidak ada kandidat yang menurunkan skor, pencarian berhenti. Lima keputusan pada route terakhir—satu keputusan untuk setiap kelompok tengah—menjadi *training targets*: nilai 1 berarti kelompok dijalankan dan nilai 0 berarti kelompok dilewati. Pencarian bertahap ini tidak mengharuskan seluruh 32 kemungkinan route dicoba.



Gambar 3.2: Pembentukan target keputusan router untuk satu artikel.

Setelah target untuk artikel data latih terbentuk, router dilatih untuk memprediksi lima keputusan tersebut berdasarkan representasi artikel. Dengan demikian, ringkasan acuan digunakan untuk menyiapkan target pelatihan, sedangkan router saat digunakan hanya menerima artikel pada prompt.

Pelatihan dan pemilihan nilai penalti

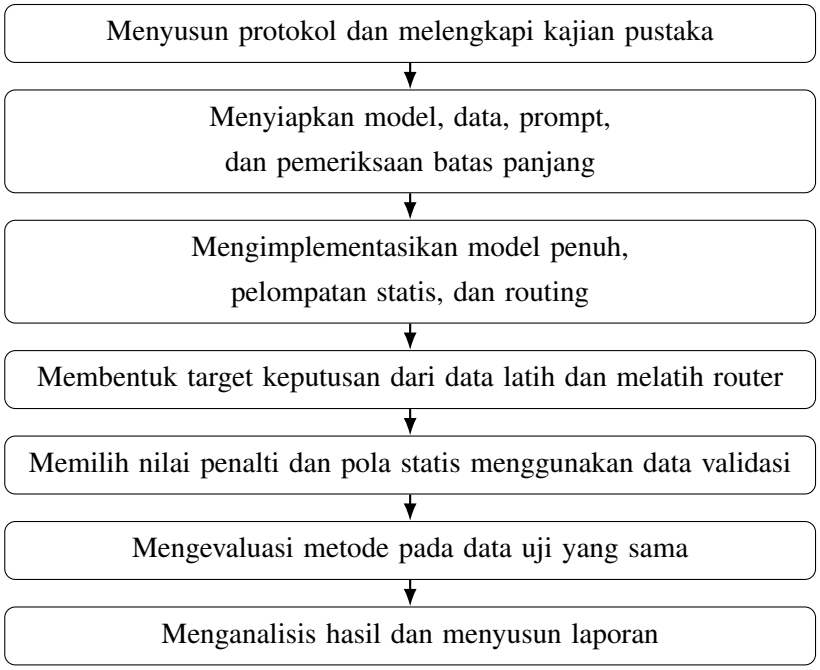
Router dilatih untuk memprediksi lima keputusan hasil pembentukan target. Pelatihan menggunakan fungsi kerugian untuk mengukur kesalahan prediksi biner sebelum keluaran router diubah menjadi keputusan aktif atau lewati (*binary cross-entropy with logits*). Bobot Qwen, termasuk bobot yang menghasilkan representasi artikel, dibekukan selama pelatihan router. Konfigurasi awal menggunakan metode pengoptimalan AdamW, laju pembelajaran 10^{-3}, peluruhan bobot 10^{-4}, paling banyak 50 epoch (putaran pelatihan atas seluruh data latih), dan penghentian awal jika kinerja validasi tidak membaik selama lima epoch berturut-turut.

Pembentukan target bergantung pada nilai λ. Nilai yang akan dibandingkan

adalah $\{0,0{,}01,0{,}05,0{,}10,0{,}20\}$. Data validasi digunakan untuk memilih satu nilai, yang kemudian dipakai pada konfigurasi router dan pemilihan pola pelompatan statis. Angka awal untuk pengacakan pemilihan sebagian data ditetapkan 42, sedangkan angka awal pelatihan router ditetapkan 43. Angka awal tambahan 44 dan 45 dapat digunakan untuk analisis ketahanan jika sumber daya mencukupi; hasilnya, apabila tersedia, dilaporkan terpisah dari hasil utama. Data uji tidak digunakan untuk membentuk target atau memilih konfigurasi.

3.4.3 Bagan Alir Metodologi

Urutan penelitian ditunjukkan pada Gambar 3.3. Tahap persiapan, implementasi, pelatihan, pemilihan konfigurasi, dan evaluasi dilakukan secara berurutan. Data uji digunakan setelah konfigurasi metode ditetapkan melalui data validasi.



Gambar 3.3: Bagan alir penelitian.

3.5 Rancangan Evaluasi

3.5.1 Metode Pembanding

Tiga metode akan dievaluasi. Metode pertama adalah Qwen3-0.6B dengan seluruh kelompok lapisan dijalankan. Metode kedua adalah pelompatan statis, yaitu

penggunaan satu pola tetap untuk seluruh artikel. Metode ketiga adalah routing adaptif, yaitu penggunaan pola yang dipilih router berdasarkan masing-masing prompt. Model penuh menjadi acuan kualitas dan waktu inferensi tanpa pelompatan. Pelompatan statis dan routing adaptif dibandingkan untuk mengetahui apakah keputusan yang menyesuaikan artikel memberikan perbedaan pada kualitas dan waktu inferensi.

Pola pelompatan statis dipilih dengan skor pada Persamaan 3.1 menggunakan data validasi dan nilai λ yang telah dipilih. Jika beberapa pola memperoleh skor yang sama, dipilih pola dengan kelompok aktif lebih sedikit. Jika masih sama, pola dengan urutan leksikografis terkecil dipilih dengan nilai 0 didahulukan daripada 1. Pola yang terpilih kemudian digunakan untuk seluruh artikel dan seluruh proses pembentukan ringkasan. Data uji tidak digunakan dalam pemilihan tersebut.

3.5.2 Pemeriksaan Implementasi

Sebelum hasil dievaluasi, implementasi akan diperiksa untuk memastikan bahwa model menghasilkan perilaku yang sesuai dengan model penuh ketika semua lapisan dijalankan. Pemeriksaan juga memastikan bahwa kelompok yang dipilih untuk dilewati tidak dieksekusi, keputusan router tidak berubah selama pembentukan ringkasan, dan penyimpanan nilai key dan value digunakan secara konsisten. Pemeriksaan diperlukan agar perbandingan kualitas dan waktu mencerminkan metode yang dirancang.

3.5.3 Kualitas Ringkasan

Kualitas ringkasan keluaran dibandingkan dengan ringkasan acuan menggunakan ROUGE-1, ROUGE-2, ROUGE-L, dan BERTScore. ROUGE-1 mengukur kesamaan kata tunggal, ROUGE-2 mengukur kesamaan pasangan kata berurutan, dan ROUGE-L mengukur kesamaan urutan kata terpanjang. BERTScore membandingkan kemiripan representasi kontekstual kata pada ringkasan keluaran dan ringkasan acuan [Zhang et al., 2020].

Untuk setiap metrik, nilai F1 akan dihitung untuk masing-masing artikel, lalu dirata-ratakan dengan bobot yang sama bagi setiap artikel. Keempat metrik dilaporkan secara terpisah. Hasil metrik kemiripan terhadap acuan tidak dengan sendirinya membuktikan bahwa semua informasi dalam ringkasan faktual atau bahwa ringkasan berkualitas dalam seluruh aspek. Pilihan implementasi ROUGE

dan konfigurasi BERTScore masih akan ditetapkan sebelum evaluasi.

Perbedaan rata-rata F1 antara routing adaptif dan setiap metode pembanding akan dilengkapi interval kepercayaan dua sisi 95% menggunakan bootstrap berpasangan. Sebanyak 10.000 pengambilan ulang dilakukan dengan mengambil artikel uji secara acak dengan pengembalian. Indeks artikel yang sama digunakan untuk kedua metode pada setiap pengambilan ulang, lalu selisih rata-rata F1 dihitung. Batas interval menggunakan persentil 2,5% dan 97,5% dari selisih hasil pengambilan ulang. Seed bootstrap adalah 42 dan digunakan terpisah dari seed pemilihan data serta seed pelatihan router. Interval dihitung secara terpisah untuk setiap metrik dan setiap pasangan perbandingan. Interval ini menggambarkan variasi antarartikel, bukan variasi antarseed pelatihan.

3.5.4 Waktu Inferensi

Efisiensi utama dinilai menggunakan waktu inferensi aktual pada perangkat dan pengaturan yang sama. Waktu total per artikel mencakup waktu untuk menghitung representasi artikel dan menjalankan router, memproses sisa prompt, serta membentuk ringkasan. Waktu pemrosesan prompt (*prefill*) dan waktu pembentukan ringkasan (*decoding*) juga dicatat secara terpisah. Jumlah token keluaran dicatat agar perbedaan waktu dapat ditafsirkan bersama panjang ringkasan yang dihasilkan. Jumlah kelompok aktif dilaporkan sebagai informasi tambahan.

Seluruh metode menggunakan prompt, batas token, mode non-thinking, dan pengaturan pembentukan ringkasan yang sama. Pengukuran menggunakan ukuran batch satu serta mencakup pemanasan dan pengulangan. Jumlah pemanasan, jumlah pengulangan, dan statistik ringkasan waktu akan ditetapkan sebelum evaluasi. Perangkat, presisi, versi perangkat lunak, serta pengaturan lain yang memengaruhi waktu juga akan dicatat. Pola kelompok yang dipilih router akan dirangkum untuk melihat seberapa sering setiap pola digunakan.

3.6 Lingkungan Penelitian

Pemeriksaan awal implementasi direncanakan pada laptop lokal dengan prosesor AMD Ryzen 3 5300U, memori terbaca sekitar 9,1 GiB, dan grafis Radeon terintegrasi. Konfigurasi awal menggunakan CPU, presisi FP32, dan ukuran batch satu. Lingkungan evaluasi akhir belum ditetapkan. Setelah waktu dan kebutuhan memori terukur, perangkat, presisi, serta jumlah artikel pada setiap bagian data ditetapkan un-

tuk eksperimen utama. Seluruh metode akan dievaluasi pada lingkungan akhir yang sama.

Versi perangkat lunak, revisi model, pengaturan thread, dan pengaturan evaluasi akan dicatat. Kesimpulan mengenai efisiensi dibatasi pada lingkungan dan konfigurasi yang digunakan dalam penelitian.

BAB IV

JADWAL PENELITIAN

4.1 Penyusunan Jadwal

Penelitian direncanakan berlangsung selama empat bulan. Jadwal mengikuti tahapan pada Bab III: persiapan kajian dan data, implementasi eksekusi kondisional, pelatihan router dan LoRA, evaluasi empat varian, analisis hasil, dan penulisan laporan. Dokumentasi dilakukan seiring pekerjaan teknis.

Tabel 4.1: Jadwal Penelitian

Kegiatan	**Bulan 1**	**Bulan 2**	**Bulan 3**	**Bulan 4**
Kajian literatur, finalisasi rancangan, dan persiapan data	•			
Implementasi model penuh, static skipping, router, dan adapter LoRA		•		
Pelatihan router dan LoRA; evaluasi kualitas serta efisiensi			•	
Analisis hasil dan penulisan laporan			•	•
Revisi dan finalisasi laporan				•

Penulisan laporan dilakukan secara paralel selama penelitian, sedangkan pembagian bulan pada tabel menunjukkan fokus utama setiap tahap.

DAFTAR PUSTAKA

CSE BUET NLP Group. XL-Sum: Dataset card. https://huggingface.co/datasets/csebuetnlp/xlsum, t.t.a. Diakses pada 6 Oktober 2026.

CSE BUET NLP Group. XL-Sum: Repository readme. https://github.com/csebuetnlp/xl-sum/blob/master/README.md, t.t.b. Diakses pada 6 Oktober 2026.

Mostafa Elhoushi, Akshat Shrivastava, Diana Liskovich, Basil Hosmer, Bram Wasti, Liangzhen Lai, Anas Mahmoud, Bilge Acun, Saurabh Agarwal, Ahmed Roman, Ahmed Aly, Beidi Chen, and Carole-Jean Wu. Layerskip: Enabling early exit inference and self-speculative decoding. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 12622–12642. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.acl-long.681. URL https://aclanthology.org/2024.acl-long.681/.

Angela Fan, Edouard Grave, and Armand Joulin. Reducing transformer depth on demand with structured dropout. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=SylO2yStDr.

Jessica Zosa Forde, Ruochen Zhang, Lintang Sutawika, Alham Fikri Aji, Samuel Cahyawijaya, Genta Indra Winata, Minghao Wu, Carsten Eickhoff, Stella Biderman, and Ellie Pavlick. Re-evaluating evaluation for multilingual summarization. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 19476–19493. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.emnlp-main.1085. URL https://aclanthology.org/2024.emnlp-main.1085/.

Tahmid Hasan, Abhik Bhattacharjee, Md. Saiful Islam, Kazi Mubasshir, Yuan-Fang Li, Yong-Bin Kang, M. Sohel Rahman, and Rifat Shahriyar. XL-Sum: Large-scale multilingual abstractive summarization for 44 languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pages 4693–4703. Association for Computational Linguistics, 2021. doi: 10.18653/v1/2021.findings-acl.413. URL https://aclanthology.org/2021.findings-acl.413/.

Akriti Jain, Saransh Sharma, Koyel Mukherjee, and Soumyabrata Pal. FiRST: Finetuning router-selective transformers for input-adaptive latency reduction. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 21957–21975. Association for Computational Linguistics, 2025. doi: 10.18653/v1/2025.findings-emnlp.1197. URL https://aclanthology.org/2025.findings-emnlp.1197/.

Ajay Kumar Jaiswal, Bodun Hu, Lu Yin, Yeonju Ro, Tianlong Chen, Shiwei Liu, and Aditya Akella. FFN-SkipLLM: A hidden gem for autoregressive decoding with adaptive feed forward skipping. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 16943–16956. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.emnlp-main.941. URL https://aclanthology.org/2024.emnlp-main.941/.

Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81. Association for Computational Linguistics, 2004. URL https://aclanthology.org/W04-1013/.

Qwen Team. Qwen3-0.6B: Model card. https://huggingface.co/Qwen/Qwen3-0.6B, 2025. Diakses pada 6 Oktober 2026.

Tal Schuster, Adam Fisch, Jai Gupta, Mostafa Dehghani, Dara Bahri, Vinh Q. Tran, Yi Tay, and Donald Metzler. Confident adaptive language modeling. In *Advances in Neural Information Processing Systems*, volume 35, pages 17456–17472, 2022. doi: 10.52202/068431-1269. URL https://proceedings.neurips.cc/paper_files/paper/2022/hash/6fac9e316a4ae75ea244ddcef1982c71-Abstract-Conference.html.

Juyun Wee, Minjae Park, and Jaeho Lee. Prompt-based depth pruning of large language models. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 65936–65948. PMLR, 2025. URL https://proceedings.mlr.press/v267/wee25a.html.

Ji Xin, Raphael Tang, Jaejun Lee, Yaoliang Yu, and Jimmy Lin. DeeBERT: Dynamic early exiting for accelerating BERT inference. In *Proceedings of the 58th Annual*

Meeting of the Association for Computational Linguistics, pages 2246–2251. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-main.204. URL https://aclanthology.org/2020.acl-main.204/.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=SkeHuCVFDr.