Kelayakan Skripsi: Dampak Efisiensi Model Computer Vision terhadap Performa Prediktif dan Kualitas Penjelasan XAI

Laporan deep research untuk pemilihan fokus, verifikasi novelty, desain eksperimen, dan rancangan benchmark harness reproducible.

Single-label image classification | Cutoff bukti: 2 September 2026 | Skripsi Inovasi Produk UGM

Putusan: layak dengan scope terkontrol. Rekomendasi utama adalah structured channel pruning dengan audit tiga checkpoint serta pemisahan explanation drift, faithfulness, dan localization.

Daftar isi

1. Ringkasan eksekutif

2. Mengecilkan bukan selalu meringankan

3. Taksonomi dan proses teknik kompresi

4. Peta literatur kompresi-XAI

5. Tiga dimensi evaluasi XAI

6. Analisis novelty arah A-H

7. Matriks perbandingan teknik

8. Dataset dan model

9. Tiga kandidat penelitian

10. Rekomendasi final

11. Pilot terkecil

12. Rekomendasi berdasarkan hardware

13. Risiko dan fallback

14. Daftar sumber beranotasi

Lampiran A. Claim-to-source ledger dan gap matrix

Audiens: mahasiswa dan pembimbing Skripsi Inovasi Produk UGM Tanggal: 2 September 2026 Cakupan: single-label image classification; literatur dan dokumentasi yang dapat diverifikasi sampai tanggal laporan Keputusan yang didukung: memilih fokus kompresi, protokol evaluasi, dataset, model, dan bentuk produk yang realistis untuk satu semester

1. Ringkasan eksekutif

Jawaban langsung

Topik ini layak dan bernilai akademik, tetapi hanya setelah dipersempit. Rumusan luas “menguji dampak kompresi model terhadap XAI” tidak lagi cukup novel. Pruning-XAI telah dibahas melalui studi perilaku di luar akurasi, human-grounded explainability, faithfulness pada model pruned, serta metode pruning yang memakai explainability. PTQ-XAI telah diuji langsung pada klasifikasi citra dalam preprint 2026. Knowledge distillation (KD)-XAI bahkan memiliki beberapa pembanding peer-reviewed yang menyelaraskan atau memvisualisasikan penjelasan teacher-student. Early-exit-XAI juga sudah memiliki pembanding langsung pada 2026.

Rekomendasi final adalah:

> **Audit dampak structured channel pruning pada perubahan bukti visual model klasifikasi citra, dengan membandingkan model padat, model segera setelah pruning, dan model setelah fine-tuning/recovery; evaluasi dipisahkan menjadi explanation drift, faithfulness, dan localization; deployment diukur pada CPU konsumen; produk berupa benchmark harness reproducible.**

Pilihan utama: ResNet-18 + Oxford-IIIT Pet + satu kriteria structured pruning + tiga level pengurangan MACs + Grad-CAM dan Integrated Gradients. ResNet-50 cukup sebagai ekstensi bila pilot menunjukkan anggaran komputasi aman. Desain inti tidak memasukkan YOLO, object detection, PTQ, KD, low-rank, dan early exit sekaligus.

Kebaruan yang aman bukan algoritmik, melainkan:

- empiris: menemukan sampel dan tingkat kompresi ketika akurasi/prediksi masih stabil tetapi penjelasan mulai bergeser;
- protokol: evaluasi berpasangan pada kelompok stable-correct, pemisahan drift-faithfulness-localization, serta tiga checkpoint sebelum/sesudah recovery;
- produk: harness yang menyimpan lineage model, hasil per sampel, attribution map, konfigurasi, metrik deployment, dan Pareto frontier.

Peringkat arah penelitian

Peringkat	Arah	Putusan
1	Structured channel pruning + tiga checkpoint + audit tiga dimensi	Direkomendasikan; kompromi terbaik antara feasibility, novelty protokol, dan produk
2	PTQ INT8 + audit XAI pada artifact deployment	Paling ringan dari sisi kompresi, tetapi novelty melemah dan gradient-XAI pada model INT8 aktual merupakan risiko penting
3	Low-rank decomposition + audit sebelum/sesudah recovery	Gap empiris paling terbuka, tetapi tuning rank, rekonstruksi layer, dan speedup aktual lebih berisiko
4	KD teacher-student	Layak, tetapi pembanding e2KD, Exp-KD, XDistillation, dan UniCAM membuat novelty umum lemah
5	Early exit/dynamic inference	Menarik tetapi routing, layer XAI per exit, dan profiling conditional compute membuat scope tinggi
6	Lightweight architecture saja	Sangat feasible sebagai baseline deployment, tetapi perbedaan arsitektur menjadi confound dan novelty rendah
7	Hybrid compression	Tidak direkomendasikan untuk scope inti satu semester

2. “Mengecilkan” bukan selalu “meringankan”

Lima keluaran efisiensi berikut harus diukur terpisah. Tidak ada implikasi otomatis di antara kelimanya.

Dimensi	Definisi operasional	Penyebab utama	Contoh kegagalan asumsi
Ukuran file	byte artifact/checkpoint yang disimpan	dtype, encoding sparse, metadata, kompresi berkas	bobot bernilai nol tetap tersimpan dalam tensor dense; mask pruning bahkan menambah state
RAM/VRAM	peak resident memory saat load/inferensi	bobot, activation, workspace kernel, allocator, batch/input	checkpoint kecil masih membutuhkan activation/workspace besar
Parameter	jumlah scalar yang dapat dilatih/disimpan	bentuk arsitektur dan factorization	parameter turun, tetapi activation dan data movement tidak berubah
MACs/FLOPs	estimasi operasi aritmetika nominal	bentuk layer, resolusi, kanal, rank	operator ber-MAC rendah dapat lebih lambat karena memory access atau kernel kecil
Latensi/throughput	waktu aktual pada runtime dan hardware tertentu	kernel, dtype, fusion, threads, cache, fallback, batch	INT8 dapat lebih lambat pada CPU lama karena quant/dequant overhead
Energi	integral daya terhadap waktu, mis. joule/inference	latensi, daya sesaat, data movement, seluruh sistem	inferensi lebih cepat dapat memakai daya lebih tinggi; MACs tidak cukup sebagai proksi

ShuffleNet V2 menunjukkan bahwa FLOPs bukan proksi langsung kecepatan: memory-access cost, parallelism, platform, dan implementasi operator memengaruhi runtime. Dokumentasi ONNX Runtime quantization juga menyatakan speedup INT8 bergantung pada model dan instruksi hardware; quant/dequant overhead dapat membuat hardware lama lebih lambat. Karena itu, skripsi harus melaporkan parameter, MACs, byte artifact, peak RAM, latency batch-1, throughput, dan bila tersedia joule/inference secara terpisah.

3. Taksonomi dan proses teknik kompresi

3.1 Unstructured pruning

Yang diubah. Bobot individual di-nol-kan menurut magnitude, gradient/Taylor, Hessian, atau kriteria lain. Bentuk tensor dan graph biasanya tidak berubah.

Alur. Umumnya train -> prune -> fine-tune, sering iteratif; versi one-shot melakukan train -> prune -> evaluate/recover. Tutorial resmi PyTorch pruning memakai `weight_orig`, `weight_mask`, dan hook. `prune.remove` menghilangkan reparameterization, tetapi tensor tetap dense berisi nol.

Dampak. Sparsity dan jumlah bobot nonzero turun. File/RAM/latency baru turun bila artifact memakai sparse encoding dan runtime memiliki sparse kernel/pattern yang cocok. Pada CPU/GPU umum, sparsity acak moderat sering tidak memberi speedup.

Kebutuhan. Implementasi algoritmik mudah, tetapi klaim deployment sulit. XAI berbasis gradien tetap kompatibel selama graph PyTorch differentiable.

Failure modes. Mask tidak mengubah ukuran graph; checkpoint dapat membesar; sparsity tidak dieksploitasi; accuracy per kelas/OOD memburuk; recovery mengubah representasi.

Kelayakan. 4/5 untuk eksperimen ilmiah, 2/5 untuk produk deployment CPU tanpa sparse runtime khusus. Cocok sebagai baseline, bukan teknik utama bila tujuan produk adalah percepatan nyata.

3.2 Structured pruning

Yang diubah. Kanal, filter, head, row/column, block, atau layer dihapus sebagai struktur. Dependency graph harus memperbarui layer berikutnya agar bentuk tensor benar-benar mengecil.

Alur. Train -> score structures -> prune -> evaluate segera -> fine-tune/recovery -> evaluate. Dapat one-shot atau iteratif. DepGraph merupakan pembanding implementasi penting untuk menangani dependency antarlayer.

Dampak. Parameter dan MACs turun; artifact dense mengecil; latensi pada CPU/GPU umum lebih mungkin turun karena operator tetap dense. Speedup tetap tidak linear karena kernel, alignment, memory access, dan layer bottleneck.

Kebutuhan. Data training/fine-tuning dan GPU terbatas berguna. ResNet-18 + transfer learning realistis di Colab/satu GPU. Grad-CAM dan IG kompatibel bila target layer semantik dipilih konsisten.

Failure modes. Pruning kanal residual yang salah merusak graph; target MACs meleset; extreme pruning menurunkan faithfulness; target layer Grad-CAM berubah resolusinya; recovery memulihkan accuracy tetapi memindahkan fokus.

Kelayakan. 4/5. Ini pilihan utama karena memberikan intervention yang jelas, checkpoint sebelum/sesudah recovery, dan deployment artifact yang dapat diukur tanpa sparse kernel khusus.

3.3 Post-training quantization (PTQ)

Yang diubah. Bobot dan/atau activation FP32 dipetakan ke integer/low-bit melalui scale dan zero-point. Static PTQ memakai calibration set; dynamic PTQ menghitung parameter activation saat inferensi.

Alur. Train FP32 -> prepare/calibrate -> convert INT8 -> evaluate/export. Untuk CNN, ONNX Runtime merekomendasikan static quantization; dynamic quantization menambah overhead runtime.

Dampak. INT8 secara ideal menyimpan bobot sekitar seperempat FP32 dan dapat memperkecil bandwidth/compute. Speedup memerlukan operator, execution provider, dan instruksi INT8 yang didukung. Unsupported operators atau Q/DQ nodes dapat mengurangi manfaat.

Kebutuhan. Tidak membutuhkan retraining, tetapi membutuhkan calibration data yang representatif. Implementasi kompresi sangat feasible.

Failure modes. Outlier activation, calibration shift, saturation, operator fallback, accuracy/class-specific behavior berubah. Risiko utama bagi topik ini: converted quantized operators biasanya forward-only; Grad-CAM/IG mungkin hanya berjalan pada fake-quant surrogate, bukan artifact deployment INT8. Dokumentasi torchao QAT membedakan fake quantization floating-point dari model converted low-bit.

Kelayakan. 5/5 untuk kompresi, 3/5 untuk audit gradient-XAI yang benar-benar menjelaskan artifact deployed. Perturbation-based XAI dapat meng-query artifact exact, tetapi lebih mahal.

3.4 Quantization-aware training (QAT)

Yang diubah. Fake-quant nodes mensimulasikan rounding/clamping selama training/fine-tuning; sesudahnya model dikonversi ke low-bit actual.

Alur. Train/initialize FP32 -> prepare QAT -> fine-tune dengan fake quantization -> convert -> export/evaluate.

Dampak. Ukuran/runtime ditentukan artifact converted dan backend, bukan graph fake-quant. QAT sering mempertahankan accuracy lebih baik daripada PTQ pada quantization agresif, tetapi membutuhkan data, backward pass, dan tuning.

Failure modes. Fake-quant dan runtime INT8 tidak identik; backend/version support berubah; gradient XAI pada fake-quant tidak otomatis faithful terhadap artifact INT8; scope training bertambah.

Kelayakan. 3/5 untuk satu semester. Jadikan ekstensi PTQ, bukan bagian wajib.

3.5 Knowledge distillation

Yang diubah. Arsitektur student yang lebih kecil dilatih mengikuti label dan output/feature/explanation teacher. Tidak ada transformasi mekanis tunggal dari teacher menjadi student.

Alur. Train/load teacher -> pilih student -> train student dengan supervised + distillation loss -> evaluate. Inference hanya menjalankan student.

Dampak. Ukuran, RAM, MACs, dan latency mengikuti arsitektur student. Training lebih mahal karena teacher forward dan kemungkinan feature/explanation alignment. Dense student umumnya mudah dideploy.

Failure modes. Capacity gap, transfer shortcut/bias teacher, prediction agreement rendah, perbedaan arsitektur membuat explanation similarity sulit diinterpretasi.

Kelayakan. 3/5. Pembanding langsung sangat padat: Good Teachers Explain, Exp-KD, XDistillation, dan UniCAM menggugurkan novelty umum teacher-student explanation comparison.

3.6 Low-rank matrix/tensor decomposition

Yang diubah. Matrix/tensor besar diganti produk faktor ber-rank r; misalnya W(m x n) menjadi A(m x r)B(r x n). Convolution dapat difaktorkan secara spatial/channel/tensor.

Alur. Train -> decompose pada beberapa rank -> evaluate segera -> fine-tune/recovery -> evaluate. Alternatifnya rank dipelajari selama training.

Dampak. Parameter dan MACs turun bila r cukup kecil. Dua operator kecil dapat menambah kernel launch/data movement; speedup teoritis tidak menjamin latency. Yu et al. CVPR 2017 dan Idelbayev & Carreira-Perpinan CVPR 2020 adalah pembanding kompresi utama, tetapi tidak mengaudit tiga dimensi XAI.

Failure modes. Pemilihan layer/rank, error rekonstruksi bertumpuk, graph lebih dalam, latency tidak turun, fine-tuning sensitif.

Kelayakan. 3/5. Gap empiris XAI paling terbuka, tetapi absence of evidence bukan bukti “belum pernah.”

3.7 Lightweight architecture

Yang diubah. Model dirancang efisien sejak awal dengan depthwise convolution, bottleneck, channel shuffle, compound scaling, dan blok hardware-aware. Contoh: MobileNetV2, EfficientNet, dan ShuffleNet V2.

Alur. Train/fine-tune arsitektur kecil secara langsung, atau gunakan sebagai student KD.

Dampak. Artifact dan MACs biasanya kecil, tetapi operator depthwise dan fragmentasi graph dapat memberi latency berbeda antar-platform.

Failure modes. Perbandingan dengan ResNet mencampur compression intervention dan inductive bias arsitektur; resolusi feature map/target Grad-CAM berbeda.

Kelayakan. 5/5 sebagai baseline deployment; novelty 1-2/5 sebagai topik utama.

3.8 Dynamic inference/early exit

Yang diubah. Side classifiers/exit ditambahkan; input mudah berhenti di layer awal menurut confidence/entropy/routing policy. BranchyNet adalah dasar klasik.

Alur. Train backbone + exits -> calibrate threshold/policy -> infer conditional path -> evaluate per-exit dan agregat.

Dampak. Average MACs/latency dapat turun, tetapi worst-case sama atau lebih tinggi karena side-head overhead. Batching GPU dapat mengurangi keuntungan karena divergence.

Failure modes. Confidence miscalibration, hard examples selalu ke exit akhir, prediction/explanation berbeda antar-exit, sulit menyamakan target layer. XAI-Exit sudah menggabungkan early exit dan attribution, sehingga novelty umum gugur.

Kelayakan. 2-3/5 untuk scope inti.

3.9 Hybrid compression

Urutan pruning -> fine-tune -> quantize, QAT + pruning, atau KD -> pruning/quantization dapat menghasilkan artifact lebih efisien, tetapi interaksi teknik membuat causal attribution sulit. Pruning vs Quantization menunjukkan perbandingan kedua teknik sendiri sudah nontrivial. Untuk satu semester, hybrid hanya layak setelah satu pipeline tunggal selesai dan memiliki fallback.

4. Peta literatur kompresi-XAI

Kelompok	Bukti langsung terkuat	Apa yang sudah diteliti	Gap yang masih defensible
Pruning-XAI	Merkle 2025; Demetriou et al. 2025; Yeom et al. 2021; X-Pruner 2023; C-SWAP 2025	perceived explainability; IROF faithfulness; XAI sebagai pruning criterion; qualitative maps	paired three-axis audit pada single-label multiclass; stable-correct; pre/post recovery; actual CPU profiling
Quantization-XAI	Chung et al. 2025 workshop; Rabbi et al. 2026 preprint; qZACH-ViT 2026 preprint	map drift, deletion/insertion, quantization-aware intrinsic explanation	peer-reviewed multiclass result dengan mask; exact deployed artifact; PTQ vs QAT; calibration sensitivity
KD-XAI	Cheng et al. 2020; XDistillation 2021; e2KD 2024; Exp-KD 2025; UniCAM 2025	knowledge visualization; explanation alignment; localization; teacher-student agreement	independent model-relative faithfulness; stable-correct audit tanpa mengoptimalkan explanations; shortcut inheritance
Low-rank-XAI	tidak ditemukan paper langsung yang lengkap	low-rank compression dan low-rank computation of CAM adalah dua hal berbeda	audit drift + faithfulness + localization sebelum/sesudah recovery; gap potensial dengan risiko pencarian
Lightweight-XAI	e2KD cross-architecture; benchmark XAI lintas arsitektur	explanation alignment/rankings bergantung arsitektur	deployment baseline; bukan causal compression trajectory
Early-exit-XAI	XAI-Exit 2026; attention-consistency preprint 2026	interpretable routing/exit attribution	rigorous post-hoc three-axis audit per exit dan routing stratum
Comparative/hybrid-XAI	Shinde & Sharma 2026 representations; generic compression comparisons	representation degradation, pruning-vs-quantization utility	matched realized latency/bytes dengan XAI tiga dimensi; scope berisiko

Pembanding terdekat yang wajib ditempatkan paling awal

1. What Do Compressed Deep Neural Networks Forget?: accuracy agregat menyembunyikan dampak kelas/sampel; bukan attribution-map study.
2. Lost in Pruning: accuracy-only stopping tidak cukup untuk OOD/noise/functional behavior.
3. Less Is More: pruning + Grad-CAM + 37.500 human tasks; perceived explainability bukan faithfulness.
4. Faithfulness in Pruned Vision Multi-Task Learning: IROF pada structured/unstructured pruning; task bukan single-label.
5. Same Predictions, Different Reasons: PTQ INT8/INT4 + Grad-CAM/LIME + similarity + insertion/deletion; novelty killer paling dekat untuk PTQ.
6. Good Teachers Explain: KD yang menyelaraskan explanations, agreement, OOD, dan localization.
7. Do Coresets, Pruning, and Quantization Preserve Representations?: REPS pada CIFAR-10/ResNet-18; representational similarity bukan XAI faithfulness.

5. Tiga dimensi evaluasi XAI

5.1 Explanation drift

Pertanyaan estimand: pada input dan target kelas yang sama, seberapa berubah attribution map model terkompresi terhadap baseline? Drift mengukur preservasi, bukan otomatis kualitas. Map yang berbeda dapat tetap faithful; map yang mirip dapat sama-sama salah.

Protokol utama:

1. bentuk kelompok stable-correct: baseline benar, compressed benar, dan prediksi kelas sama;
2. jelaskan logit target yang sama, idealnya kelas benar/common prediction;
3. simpan strata lain: stable-wrong, correct-to-wrong, wrong-to-correct, changed-wrong;
4. laporkan proporsi strata agar conditioning tidak menyembunyikan failures;
5. hitung distribusi per sampel dan paired bootstrap CI, bukan mean saja.

Metrik	Kekuatan	Kelemahan	Status rekomendasi
Spearman rank correlation	fokus pada urutan; tahan scaling monotonic	ties dan pixel noise; mengabaikan magnitude	Primer setelah normalisasi/flatten konsisten
Top-k overlap/Jaccard	mudah menilai perpindahan region paling penting	sensitif k/threshold	Primer, laporkan k=5%, 10%, 20%
Cosine similarity	mempertahankan pola arah global	sensitif centering/sign; map nonnegative dapat tampak mirip	Sekunder
SSIM	menangkap struktur spasial lokal	dirancang untuk natural-image quality; sensitif dynamic range/window	Sekunder/sensitivity analysis
RBO	top-weighted ranking overlap	pixel ties dan full fixed ranking membuat interpretasi lemah	Tidak primer; hanya jika unit adalah superpixel/ranked region

Sanity Checks for Saliency Maps memakai rank correlation dan SSIM untuk membandingkan peta dan menunjukkan bahwa visual appeal saja dapat menyesatkan. Drift metric harus disertai model-parameter randomization sanity check.

5.2 Faithfulness

Pertanyaan estimand: apakah fitur yang diberi importance tinggi benar-benar mengubah output model yang sedang dijelaskan? Faithfulness selalu relatif terhadap predictor saat ini, bukan kemiripan dengan baseline/teacher.

Metrik	Operasi	Interpretasi	Caveat
Deletion AUC	hapus region penting secara progresif	AUC lebih rendah biasanya lebih faithful	masking OOD, baseline dan step size menentukan hasil
Insertion AUC	masukkan region penting dari baseline	AUC lebih tinggi biasanya lebih faithful	baseline/inpainting dan ranking confound
IROF	hapus superpixel menurut mean relevance	region-level, lebih hemat daripada pixel removal	segmenter dan baseline tetap memengaruhi
Faithfulness correlation	korelasikan attribution mass dan output change pada subset acak	tinggi lebih baik	stochastic variance, linearity, OOD

Metrik	Operasi	Interpretasi	Caveat
Comprehensiveness/sufficiency	remove/retain rationale	necessity/sufficiency	berasal dari NLP; image adaptation sama-sama perturbation-based

Benchmarking Deletion Metrics menunjukkan bahwa insertion/deletion harus ditangani hati-hati, termasuk masalah OOD. Mitigasi yang disarankan:

- pra-registrasi unit perturbasi, target score/logit, jumlah step, dan baseline;
- gunakan patch/superpixel, bukan pixel tunggal;
- uji sedikitnya dua baseline, misalnya blur/mean dan ROAD-style imputation;
- sertakan random serta least-relevant controls;
- gunakan protokol identik untuk seluruh model;
- laporkan sensitivitas baseline, bukan memilih baseline terbaik sesudah melihat hasil.

ROAR mengurangi distribution mismatch dengan retraining, tetapi predictor yang dievaluasi berubah dan biayanya tinggi. ROAD mengurangi masking confound tanpa retraining, tetapi tetap mendefinisikan intervention tertentu. Tidak ada masking metric yang baseline-free.

5.3 Localization/plausibility

Pertanyaan estimand: apakah attribution berada pada region yang secara eksternal dianggap relevan? Ini external plausibility, bukan model faithfulness.

Metrik	Keterangan	Rekomendasi
Relevance Mass Accuracy / attribution mass in mask	positive attribution di dalam mask dibagi total positive attribution	Primer untuk dense mask
Energy-Based Pointing Game	pada map nonnegative hampir satu keluarga dengan RMA	Jangan dihitung sebagai bukti independen ganda
Pointing Game	apakah pixel maksimum berada di mask/box	Sekunder; sangat kasar
Top-k mask overlap	intersection attribution top-k dengan mask	Sekunder; laporkan beberapa k
IoU thresholded map	overlap dua mask biner	Sensitif threshold dan luas box; bukan primer tunggal

Mask segmentation bukan ground truth proses internal. Pada klasifikasi ras, kepala/telinga dapat lebih diskriminatif daripada seluruh tubuh; background juga dapat benar-benar dipakai model. Karena itu, Oxford Pet sebaiknya melaporkan localization pada trimap seluruh hewan dan head ROI secara terpisah, ditambah random-map/area baseline.

6. Analisis novelty arah A-H

Ide	Status	Bukti yang menggugurkan klaim luas	Reformulasi defensible
A. Pruning + drift + faithfulness + localization	Sudah diteliti sebagian; gap metodologis	Merkle; Demetriou; Yeom; X-Pruner; C-SWAP	single-label multiclass, stable-correct, tiga checkpoint, tiga dimensi, actual CPU
B. PTQ/QAT + tiga dimensi	PTQ diteliti langsung sebagian; QAT belum cukup bukti	Rabbi 2026; Chung 2025; qZACH-ViT	exact artifact vs fake-quant, mask localization, calibration/QAT comparison, deployment parity
C. KD teacher-student tiga dimensi	Sudah diteliti langsung/sebagian; padat	e2KD, Exp-KD, XDistillation, UniCAM	independent faithfulness per model dan shortcut inheritance; novelty sedang-rendah
D. Low-rank + performa/XAI	Berpotensi novel tetapi berisiko	paper kompresi low-rank tidak mengaudit XAI; LowRank-CAM bukan compression predictor	tiga-axis audit pada decomposed/recovered model; hindari klaim “pertama”
E. Dua teknik pada budget sama	Gap protokol kuat; scope risk	pruning-vs-quantization studies memakai utility/representation, bukan paket XAI lengkap	samakan satu budget primer, idealnya measured latency atau bytes; report metrik lain apa adanya
F. Baseline-segera compressed-recovered	Gap metodologis kuat	studi recovery umum ada, tetapi full paired XAI trajectory tidak ditemukan kuat	jadikan kontribusi protokol inti
G. Titik accuracy stabil, XAI turun	Fenomena sudah ditunjukkan; estimasi breakpoint masih terbuka	Rabbi 2026; input-compression paper 2026; Merkle sweet spot	definisikan accuracy-preserving region dan breakpoint per dimensi sebelum analisis
H. Fine-tuning memulihkan accuracy dengan fokus/shortcut baru	Belum cukup bukti langsung; menjanjikan	recovery diketahui mengubah bobot, tetapi bukti compression-XAI lengkap jarang	klaim sebagai audit perubahan, bukan pembuktian shortcut kausal tanpa intervention khusus

Jenis novelty

- Algoritmik: tidak ditargetkan; sangat sulit karena Yeom, X-Pruner, C-SWAP, e2KD, dan qZACH sudah mengoptimalkan kompresi/explanation.
- Empiris: kuat bila menghasilkan paired per-sample evidence dan breakpoint baru pada setting terkontrol.
- Protokol evaluasi: paling defensible melalui stable-correct, tiga dimensi, tiga checkpoint, dan deployment metrics terpisah.
- Produk/benchmark harness: sangat sesuai Skripsi Inovasi Produk bila reproducible dan bukan sekadar notebook.
- Dataset-only: lemah. Mengganti dataset tanpa construct/protocol baru bukan novelty kuat.

7. Matriks perbandingan teknik

Skala: feasibility/akademik/novelty/kesesuaian produk 1 rendah-5 tinggi; beban komputasi dan scope risk 1 rendah-5 tinggi.

Teknik	Proses	File	RAM	MACs	Latency CPU	Grad-CAM/IG	Kepadatan prior	F	A	N	Beban	Risk	Produk
Unstructured pruning	train-prune-FT	hanya dengan sparse encoding	tidak otomatis	nonzero teoretis turun	rendah tanpa sparse kernel	baik	tinggi	4	3	2	3	3	3
Structured channel pruning	train-prune-eval-FT	turun	cenderung turun	turun	potensial nyata, ukur	baik	tinggi tetapi audit lengkap jarang	4	5	3	3	3	5

Teknik	Proses	File	RAM	MACs	Latency CPU	Grad-CAM/IG	Kepadatan prior	F	A	N	Beban	Risk	Produk
Static PTQ INT8	train-calibrate-convert	turun ~4x ideal	cenderung turun	nominal conv sama, bit-op turun	baik pada CPU mendukung	converted graph berisiko	direct 2025-26	5	4	2	1	3	4
QAT INT8	prepare-train-convert	turun	cenderung turun	bit-op turun	backend-dependent	fake-quant baik; artifact risk	sedang/baru	3	4	3	4	4	4
KD	teacher-train student	sesuai student	sesuai student	sesuai student	umumnya baik	baik	sangat padat	3	4	2	4	4	4
Low-rank	train-decompose-eval-FT	turun	dapat turun	turun bila rank tepat	tidak pasti karena extra ops	baik	XAI langsung jarang	3	4	4	4	4	4
Lightweight architecture	train/fine-tune kecil	turun	turun	turun	biasanya baik tetapi platform-specific	baik, target layer berbeda	tinggi	5	2	1	2	2	4
Early exit	train exits-calibrate route	bisa naik karena heads	bisa naik sedikit	average turun	input/batch-dependent	rumit per exit	direct 2026	2	4	3	4	5	4
Hybrid	beberapa tahap	paling potensial	potensial	potensial	paling backend-dependent	kompleks	tinggi pada efficiency	2	4	3	5	5	4

8. Dataset dan model

Dataset

Dataset	Ukuran/anotasi	Lisensi/status	Kesesuaian
Oxford-IIIT Pet	7.349 citra, 37 breed, head ROI, pixel trimap setiap citra	official page menyatakan CC BY-SA 4.0; copyright gambar tetap pemilik	Terbaik untuk satu semester dan dual localization construct
CUB-200-2011	11.788, 200 spesies, box, 15 parts, 312 attributes; segmentations tambahan	non-commercial research/education; overlap ImageNet/Flickr	kaya tetapi lebih berat dan leakage pretraining harus diaudit
FGVC-Aircraft	10.000, 100 variants, box	non-commercial research	realistis, box-only, context correlation
PASCAL VOC/Open Images	multilabel scenes, boxes/masks	hak gambar heterogen	kurang cocok sebagai core single-label

Sumber resmi: Oxford-IIIT Pet dan CUB-200-2011.

Model

ResNet-18 dipilih sebagai model utama karena graph residual cukup representatif, ukuran training/fine-tuning realistis, target convolutional stage jelas, dan structured pruning memiliki tooling matang. ResNet-50 boleh menjadi validasi ukuran keluarga bila komputasi tersedia.

Membandingkan ResNet-50 teacher dengan MobileNetV2 student mencampur teknik KD, kapasitas, operator, receptive field, feature-map resolution, dan inductive bias. Explanation drift lintas arsitektur tidak dapat diinterpretasikan sebagai efek kompresi tunggal. Jika dipakai, framing-nya harus “teacher-student functional transfer,” bukan before/after compression yang identik.

9. Tiga kandidat penelitian

Kandidat 1 - paling feasible: audit PTQ INT8 pada artifact deployment

Judul Indonesia: Audit Performa, Pergeseran Penjelasan, dan Lokalisasi Model Klasifikasi Citra Terkuantisasi pada CPU Konsumen Judul Inggris: Auditing Predictive Performance, Explanation Drift, and Localization of Quantized Image Classifiers on Consumer CPUs

Masalah. PTQ mudah mengecilkan artifact dan dapat mempercepat CPU, tetapi accuracy tidak menjamin explanation preservation; gradient-XAI mungkin tidak berjalan pada graph INT8 actual.

RQ. (1) Bagaimana INT8 PTQ mengubah accuracy/agreement dan latency? (2) Pada stable-correct, apakah attribution exact-deployment drift? (3) Apakah faithfulness dan localization berubah? (4) Seberapa berbeda fake-quant surrogate dari artifact actual?

Hipotesis. INT8 mempertahankan accuracy lebih baik daripada map similarity; efek bergantung arsitektur/calibration; perturbation-XAI pada artifact dapat mendeteksi drift yang tidak terlihat dari accuracy.

Kontribusi aman. Audit multiclass dengan mask, deployment parity, dan protokol per sampel; bukan paper pertama quantization-XAI.

Pembanding. Rabbi et al. 2026; Chung et al. 2025; qZACH-ViT 2026. Perbedaan: Oxford Pet 37 kelas, mask/ROI, exact CPU artifact, calibration sensitivity, stable-correct.

Desain. ResNet-18; Oxford Pet; FP32 + static PTQ INT8 dengan MinMax/Entropy/Percentile atau dua calibration sizes; XAI utama perturbation-based (RISE/LIME) pada artifact; Grad-CAM/IG hanya bila exact graph mendukung backward, atau dilabeli jelas sebagai surrogate analysis. Predictive: accuracy, macro-F1, NLL/ECE, agreement. XAI: Spearman/top-k, deletion/insertion atau ROAD, RMA/head-ROI. Deployment: bytes, peak RSS, batch-1 median/p95, throughput, optional joule/inference.

Varian. 4-7 artifact; tanpa multi-seed training bila baseline checkpoint sama, tetapi ulang calibration/bootstrap. Hardware. Tanpa GPU memungkinkan; CPU dengan instruksi INT8 lebih baik. Risiko. Gradient-XAI incompatibility dan novelty preprint 2026. Fallback. Batasi INT8 static, gunakan black-box XAI, dan jadikan gradient parity sebagai limitation. Batas klaim. Hanya backend/hardware/version yang diuji. Produk. Export-and-audit harness untuk FP32/INT8.

Kandidat 2 - novelty paling kuat: low-rank decomposition tiga checkpoint

Judul Indonesia: Audit Perubahan Performa dan Penjelasan XAI pada Kompresi Low-Rank Model Klasifikasi Citra Judul Inggris: Auditing Predictive and XAI Explanation Changes under Low-Rank Compression of Image Classifiers

Masalah. Low-rank mengurangi parameter/MACs, tetapi efek terhadap bukti visual dan pemulihan sesudah fine-tuning belum memiliki bukti langsung yang padat.

RQ. Bagaimana rank memengaruhi accuracy, latency, drift, faithfulness, dan localization sebelum/sesudah recovery? Apakah recovery memulihkan prediction melalui fokus visual yang berbeda?

Hipotesis. Moderate rank reduction mempertahankan accuracy, tetapi decomposition segera meningkatkan drift; recovery memulihkan accuracy lebih cepat daripada localization/faithfulness.

Kontribusi aman. Studi empiris/protokol pada gap yang jarang, bukan algoritma factorization baru dan bukan klaim “pertama.”

Pembanding. Yu et al. 2017 dan Idelbayev & Carreira-Perpinan 2020 untuk compression; tidak mengaudit XAI. LowRank-CAM tidak relevan karena mengompresi perhitungan explanation, bukan predictor.

Desain. ResNet-18; factorize subset Conv/FC yang pra-registrasi; ranks yang menargetkan 25/50/70% MAC reduction; checkpoint baseline, decomposed-immediate, recovered; Grad-CAM + IG; metric suite sama dengan rekomendasi.

Varian. 1 + 3 immediate + 3 recovered = 7 per seed; 3 seed ideal (21). Hardware. Satu GPU memadai; Colab mungkin dengan satu seed/pilot. Risiko. Rank allocation, graph engineering, dan latency tidak turun. Fallback. Factorize hanya layer 3-4/FC dan gunakan dua rank; jadikan parameter/MACs sebagai efficiency utama bila latency gagal, dengan klaim terbatas. Produk. Low-rank model lineage and XAI audit harness.

Kandidat 3 - kompromi terbaik dan rekomendasi final: structured pruning recovery audit

Judul Indonesia: Evaluasi Pergeseran, Faithfulness, dan Lokalisasi Penjelasan XAI pada Model Klasifikasi Citra yang Mengalami Structured Pruning Judul Inggris: Evaluating Explanation Drift, Faithfulness, and Localization in Structurally Pruned Image Classifiers

Masalah. Structured pruning dapat menghasilkan model dense yang lebih kecil dan cepat, tetapi accuracy-only selection dapat melewatkan perubahan bukti visual; recovery dapat mengubah fokus.

RQ. (1) Bagaimana level pruning memengaruhi accuracy, agreement, MACs, latency, dan memory? (2) Pada stable-correct, kapan drift meningkat? (3) Apakah faithfulness/localization menurun di accuracy-preserving region? (4) Apakah recovery memulihkan metrik prediktif dan XAI dengan laju sama?

Hipotesis. Ada region pruning moderat dengan accuracy stabil tetapi drift meningkat; extreme pruning menurunkan faithfulness/localization; recovery memulihkan accuracy lebih cepat daripada seluruh dimensi XAI.

Kontribusi aman. Paired three-axis, recovery-trajectory, per-sample deployment audit; bukan pruning/XAI algorithm baru.

Pembanding. Merkle 2025; Demetriou 2025; Yeom 2021; X-Pruner 2023; C-SWAP 2025. Perbedaan: single-label multiclass, stable-correct, mask + head ROI, three checkpoints, actual CPU.

Model/dataset. ResNet-18 utama; Oxford Pet 37 kelas; ResNet-50 opsional. Satu kriteria channel importance (L1/L2 norm) sebagai inti; Taylor hanya ekstensi setelah pilot.

Level. target pengurangan MACs 25%, 50%, 70%; target disesuaikan pilot agar tidak menghasilkan graph invalid. XAI. Grad-CAM + Integrated Gradients. Prediktif. top-1, macro-F1, NLL, ECE, per-class recall, agreement. XAI. Spearman/top-k/SSIM sekunder; deletion/IROF/ROAD sensitivity; RMA + Pointing Game; randomization sanity check. Deployment. params, MACs, bytes ONNX/TorchScript, peak RSS, load time, median/p95 latency batch-1, throughput, optional joule/inference.

Desain. Baseline -> prune level -> immediate evaluation -> fixed-budget recovery -> evaluation. Hasil per sample disimpan sebagai Parquet/JSONL; paired bootstrap CI dan effect size; accuracy-preserving region dipraregistrasi, misalnya <=1 pp absolute accuracy drop.

Varian. 7 model per seed; 3 seeds ideal = 21. Minimum defensible: satu seed training yang dikunci + bootstrap per sampel, dengan klaim generalisasi terbatas. Hardware. Colab/satu GPU memadai. Risiko. 70% MACs gagal, Grad-CAM target layer berubah, eksperimen 3 seed mahal. Fallback. ResNet-18 saja, level 25/50%, Grad-CAM full test + IG stratified subset, satu importance criterion. Batas klaim. Tidak membuktikan reasoning kausal, tidak menggeneralisasi ke semua

pruner/hardware. Produk. CLI/config-driven benchmark harness dengan model lineage, profiler, metric registry, artifact cache, dan report generator.

10. Rekomendasi final dan alasan

Pilih Kandidat 3: structured channel pruning recovery audit.

Alasannya:

1. artifact hasil pruning tetap dense dan lebih mudah memberi speedup pada CPU umum daripada unstructured masks;
2. Grad-CAM/IG tetap dapat dihitung pada model actual, berbeda dari risiko graph quantized;
3. tiga checkpoint menyediakan intervention yang jelas untuk menilai kerusakan langsung dan efek recovery;
4. Oxford Pet memberi label klasifikasi, dense foreground mask, dan head ROI dalam dataset kecil berlisensi jelas;
5. novelty luas memang gugur, tetapi kombinasi stable-correct + tiga dimensi + recovery trajectory + actual deployment masih merupakan gap protokol yang defensible;
6. harness audit sesuai struktur Skripsi Inovasi Produk UGM: masalah nyata, rancangan produk, implementasi, pengujian, evaluasi.

Low-rank menjadi pilihan kedua bila pembimbing memprioritaskan novelty dan GPU tersedia. PTQ menjadi fallback tanpa GPU, dengan konsekuensi harus memakai black-box/perturbation XAI untuk artifact actual atau membatasi klaim surrogate.

11. Pilot terkecil

Pilot harus selesai sebelum judul final dikunci.

Komponen	Minimum pilot
Dataset	Oxford Pet split resmi; verifikasi transform mask pada 20 citra
Model	ResNet-18 transfer learning, satu seed
Compression	baseline; structured pruning target 50% MACs; immediate; recovery 5-10 epoch
Sampel XAI	Grad-CAM 256 test images; IG pada 64 stable-correct stratified images
Drift	Spearman + top-10% Jaccard; target class sama
Faithfulness	deletion 20 steps dengan blur; random/least-relevant control; ROAD bila tersedia
Localization	RMA pada trimap dan head ROI; Pointing Game sekunder
Deployment	warm-up, thread count tetap, >=1000 batch-1 repeats; median/p95; peak RSS; artifact bytes
Output	satu Parquet/JSONL per sampel, config, hashes, 12 contoh audit visual, Pareto mini-report

Kriteria go/no-go:

- physical pruning benar-benar mengubah tensor shape dan MACs;
- model dapat diekspor dan latency terukur stabil (CV rendah setelah warm-up);
- sedikitnya sekitar 150 stable-correct images tersedia untuk paired pilot;
- mask alignment benar pada audit visual;
- semua tahap selesai dalam anggaran komputasi yang dapat dikalikan ke eksperimen penuh;
- tidak ada silent mismatch antara target logit/model/layer XAI.

12. Rekomendasi berdasarkan hardware

Kondisi	Rekomendasi
Tanpa GPU	PTQ INT8 + black-box XAI exact artifact; atau gunakan pretrained/frozen baseline dan pilot structured pruning tanpa full retraining; scope satu model
GPU terbatas/Colab	ResNet-18 structured pruning, 2-3 levels, fixed recovery budget, Grad-CAM full + IG subset
Satu GPU memadai	desain rekomendasi 3 levels x 3 seeds; tambah ResNet-50 hanya setelah ResNet-18 lengkap; atau pilih low-rank untuk novelty lebih tinggi

13. Risiko dan fallback

Risiko	Dampak	Mitigasi/fallback
Novelty dikalahkan paper baru	klaim utama lemah	framing kontribusi protokol/produk; literature update sebelum proposal final
Metric OOD/masking	faithfulness misleading	dua baseline, ROAD/random control, sensitivity report
Stable-correct selection bias	failures tersembunyi	laporkan semua strata dan counts; drift utama tetap stable-correct
Mask bukan ground truth reasoning	overclaim localization	sebut plausibility; trimap/head ROI terpisah; random-area baseline
CPU latency noisy	perbandingan tidak stabil	lock threads/power, warm-up, repeated timing, median/p95, hardware metadata
Recovery compute tinggi	eksperimen tidak selesai	ResNet-18 saja, dua level, satu criterion, fixed short recovery
IG terlalu mahal	evaluasi tertunda	subset stratified pra-registrasi; Grad-CAM full
Pruning graph gagal	artifact invalid	gunakan dependency-aware library; audit tensor shapes/export di pilot
Hasil null	kontribusi dianggap lemah	null yang ketat tetap bernilai: batas equivalence/CI, product validation, per-sample failure taxonomy
Scope creep	tidak selesai	larang penambahan YOLO/dataset/technique sebelum core matrix selesai

14. Daftar sumber beranotasi

1 Hooker et al. - What Do Compressed Deep Neural Networks Forget? Preprint, 2019-2021. Paper. Menunjukkan aggregate accuracy menyembunyikan dampak kelas/sampel dan Pruning Identified Exemplars. Bukan XAI-map study.

2 Liebenwein et al. - Lost in Pruning. MLSys 2021, peer-reviewed. Paper. Pruning harus dinilai pada functional/OOD/noise metrics, bukan accuracy saja.

3 Merkle et al. - Less Is More. IEEE Access 2025, peer-reviewed; preprint. VGG16/Imagenette, iterative unstructured pruning, Grad-CAM, 37.500 human tasks; perceived explainability berbeda dari decision utility/faithfulness.

4 Demetriou et al. - Faithfulness of Feature Attribution in Pruned Vision MTL. xAI 2025 late-breaking workshop. Paper. IROF pada structured/unstructured pruning; bukan single-label classification.

5 Yeom et al. - Pruning by Explaining. Pattern Recognition 2021. First-party page. LRP dipakai sebagai pruning criterion; bukan post-compression input-attribution audit.

6 Yu & Xiang - X-Pruner. CVPR 2023. Paper. Explainability-aware masks untuk structured ViT pruning; map evidence terutama kualitatif.

7 Bauvin et al. - C-SWAP. BMVC 2025. Paper. Causal-aware one-shot structured pruning tanpa fine-tuning; sangat dekat untuk novelty algorithmic.

8 Rabbi et al. - Same Predictions, Different Reasons. arXiv preprint, Juli 2026. Paper. PTQ INT8/INT4, Grad-CAM/LIME, similarity dan deletion/insertion; direct novelty killer untuk PTQ-XAI, tetapi dua dataset biner kecil dan tanpa hardware profiling.

9 Chung et al. - Understanding the Impact of Quantization on Model Explainability. HCAI/CIKM workshop 2025. Paper. Preliminary evidence pada Grad-CAM, IG, dan LRP.

10 Parchami-Araghi et al. - Good Teachers Explain. ECCV 2024. Paper. Explanation-enhanced KD meningkatkan agreement, OOD, dan localization; generic KD-explanation alignment bukan novelty.

11 Sun et al. - Explainability-based Knowledge Distillation. Pattern Recognition 2025. DOI. CAM alignment sebagai knowledge; audit terikat algoritma baru.

12 Adhane et al. - On Explaining Knowledge Distillation. WACV 2025. Paper. UniCAM/FSS/RS memvisualisasikan distilled/residual features; bukan standard faithfulness/localization audit.

13 Cheng et al. - Explaining KD by Quantifying the Knowledge. CVPR 2020. Paper. Menganalisis visual concepts dan optimization stability dalam KD.

14 Shinde & Sharma - Do Coresets, Pruning, and Quantization Preserve Representations? GRaM/PMLR workshop 2026. Paper. REPS pada CIFAR-10/ResNet-18; representation similarity bukan explanation faithfulness.

15 Hedström et al. - Quantus. JMLR 2023. Paper. Toolkit/taksonomi >35 metrics; library availability bukan validasi konstruk.

16 Adebayo et al. - Sanity Checks for Saliency Maps. NeurIPS 2018. Paper. Beberapa saliency methods tidak sensitif pada model/data; randomization checks wajib.

17 Wang & Wang - Benchmarking Deletion Metrics with Principled Explanations. ICML 2024. Paper. Membahas OOD dan failure modes insertion/deletion.

18 Hooker et al. - ROAR benchmark. NeurIPS 2019. Paper. Remove-and-retrain menangani distribution mismatch tetapi mengganti predictor dan mahal.

19 Rong et al. - ROAD. ICML 2022. Paper. Removal/debias tanpa retraining; mengurangi leakage confound.

20 Selvaraju et al. - Grad-CAM. ICCV 2017. Paper. Dasar class-discriminative localization; coarse map dan layer choice harus dilaporkan.

21 Parkhi et al. - Oxford-IIIT Pet. CVPR 2012; dataset. 37 breed, head ROI, trimap; pilihan utama.

22 Wah et al. - CUB-200-2011. Caltech technical report/dataset; official page. Rich annotations, tetapi non-commercial dan overlap pretraining.

23 Ma et al. - ShuffleNet V2. ECCV 2018. Paper. Bukti primer bahwa FLOPs dan latency tidak ekuivalen.

24 ONNX Runtime - Quantize ONNX Models. Dokumentasi resmi, diakses 2026-09-02. Docs. Static/dynamic PTQ, data types, backend caveats, dan failure to speed up.

25 PyTorch/torchao - QAT Workflow. Dokumentasi resmi, 2026. Docs. Fake-quant prepare/train/convert dan support constraints.

26 Yu et al. - Low Rank and Sparse Decomposition. CVPR 2017. Paper. Compression baseline; tidak mengaudit XAI.

27 Idelbayev & Carreira-Perpinan - Learning Rank of Each Layer. CVPR 2020. Paper. Low-rank baseline dan rank learning; tidak mengaudit attribution.

28 Teerapittayanon et al. - BranchyNet. ICPR 2016. DOI. Early-exit foundation.

29 Rahmath et al. - XAI-Exit. IEEE TNNLS 2026. DOI. Early exit dengan attribution trajectories; novelty killer untuk framing umum.

30 Kuzmin et al. - Pruning vs Quantization: Which Is Better? NeurIPS 2023. Paper. Menunjukkan matched compression comparison sendiri kompleks dan budget definition penting.

Lampiran A. Claim-to-source ledger dan gap matrix

Klaim material	Bukti utama	Confidence	Kontradiksi/batas	Gap berikutnya
Accuracy tidak menjamin perilaku sama	Hooker; Liebenwein; Rabbi	tinggi	behavior, explanation, representation adalah construct berbeda	paired per-sample audit
Pruning-XAI bukan novelty umum	Merkle; Demetriou; Yeom; X-Pruner; C-SWAP	tinggi	sebagian bukan single-label atau bukan posthoc audit	three-axis recovery protocol
PTQ dapat mengubah explanation saat prediction sama	Rabbi 2026	sedang-tinggi	preprint, dataset kecil, reproducibility wording PTQ tidak konsisten	multiclass/mask/exact backend replication
KD explanation alignment sudah padat	e2KD; Exp-KD; XDistillation; UniCAM	tinggi	alignment bukan faithfulness	independent model-relative audit
Low-rank-XAI direct evidence jarang	targeted search + compression originals	sedang	absence search tidak membuktikan nonexistence	literature update sebelum klaim novelty
FLOPs tidak sama latency	ShuffleNet V2; ONNX docs	tinggi	hasil hardware-specific	measure target CPU
Gradient XAI pada INT8 artifact berisiko	torchao docs + converted operator behavior	tinggi	support dapat berubah menurut backend/version	local pilot exact graph
Localization bukan faithfulness	Quantus taxonomy; CLEVR-XAI/RMA family	tinggi	external mask tetap berguna untuk plausibility	report constructs separately

Catatan metode pencarian dan alasan berhenti

Pencarian dilakukan secara bertahap pada exact seed titles, pasangan istilah compression-XAI, venue primer (CVF/PMLR/JMLR/OpenReview/IEEE/ACM/arXiv), dokumentasi framework/runtime resmi, dan situs dataset resmi. Gelombang kedua menargetkan pembanding yang dapat menggugurkan novelty: explanation-aware pruning/KD, PTQ explanation drift 2025-2026, early-exit XAI, low-rank direct audit, matched-budget comparison, serta fine-tuning recovery. Pencarian dihentikan ketika setiap teknik memiliki pembanding/gap yang dapat dinilai, klaim deployment memiliki sumber resmi, konflik metric OOD dan quantized-gradient telah dibatasi, dan tambahan hasil berulang tidak mengubah peringkat rekomendasi. Gap yang tetap tidak pasti dinyatakan eksplisit, terutama absence of direct low-rank-XAI study dan exact backward support pada backend quantization yang akan dipilih.